


NO. e0451c43122eb0d9 | 2026-04-27 14:53:01

- 题目：基于Hive+Spark的汽车销售数据分析与研究
- 作者：江磊
- 检测所属单位：马鞍山学院

📄 论文字符数：35086 📄 论文页数：59 📊 表格数量：8 🖼️ 图片数量：48

检测结果



45.93%

疑似AIGC生成占比

54.07%

人工撰写占比

结果分布

序号	章节	疑似AIGC生成文字/章节总字数	疑似AIGC生成章节占比	人工撰写占比
1	摘要	453/453	100.0%	0.0%
2	Abstract	220/222	99.0%	1.0%
3	1 绪论	1899/2813	67.0%	33.0%
4	2 核心技术与工具基础	728/2776	26.0%	74.0%
5	3 需求分析与可行性论证	873/1487	58.0%	42.0%
6	4 数据采集与预处理	1828/2840	64.0%	36.0%
7	5 数据存储处理与特色分析	749/6955	10.0%	90.0%

8	6 可视化设计与实现	1653/3056	54.0%	46.0%
9	7 总结与展望	1273/1304	97.0%	3.0%

*注:格式规范的情况下可准确识别章节,若论文中无章节,可能会识别有误。



文字标注

■ 疑似AIGC生成 ■ 人工撰写

基于Hive+Spark的汽车销售数据分析与研究

马鞍山学院

Ma'anshan University

2026 届本科毕业设计（论文）

题 目 基于Hive+SPark的汽车销售数
据分析与研究

学 生 姓 名 江磊

学 号 22404291

专 业 班 级 数据科学与大数据技术数222

学 院 大数据与人工智能学院

指 导 教 师 郑心科

完 成 日 期 2026年5月

教务处 制

马鞍山学院学位论文原创性声明

本人声明：所呈交的学位论文是本人在导师的指导下，独立进行研究取得的成果。除文中已经注明引用的内容外，本论文不包含其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

学位论文作者：江磊

日期： 2026 年4月20日

马鞍山学院学位论文授权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权马鞍山学院将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

保 密，在__年解密后适用本授权书。

不保密。

学位论文作者签名：

江磊

指导教师签名：

郑心科

日期：

2026年4月20日

日期：

2026年4月20日

马鞍山学院

毕业设计(论文)任务书

课题名称

基于Hive+Spark的汽车销售数据分析与研究

院 别

大数据与人工智能学院

专业班级

数据科学与大数据技术222班

姓 名

江磊

学 号

22404291

毕业设计（论文）的主要内容及要求：

内容：

- 1、查阅资料，完成开题报告，明确基于Hive+Spark的电动汽车销售数据分析研究思路与技术路线。
- 2、开展研究需求分析，完成公共数据集采集，利用DataX将数据导入HDFS，在Hive构建数据仓库，并进行数据分层处理，最后将处理好的数据导回到MySQL中进行分析与处理。
- 3、掌握Hadoop、Hive、Spark等大数据处理技术，以及MySQL数据库使用技术，运用Hive进行数据分析，利用FineBI实现数据可视化展示，完成电动汽车销售数据分析与研究。
- 4、按照毕业设计要求 and 论文模板，规范撰写毕业论文，确保内容完整、格式正确。
- 5、完成论文修改、查重检测及答辩准备，整理并归档研究资料，总结适用于行业的数据分析方法流程，为企业提供市场洞察与策略制定参考。

要求：

- 1、认真研读《马鞍山学院本科毕业设计(论文)工作管理规定》，熟悉毕业设计的评分标准、工作流程、答辩工作规程、资料归档目录、工作内容基本要求。
- 2、要求参考文献12篇以上，其中外文参考资料不少于2篇，近三年的不低于6篇。

- 3、严格按照毕业设计进度安排，分步、按时完成各阶段的工作任务，完成软件的编写、调试和上交。
- 4、严格按照学院毕业论文的撰写规范、模板、摘要和参考文献等范本格式进行论文的撰写。
- 5、完成毕业论文，正文字数需1.2-1.5万字左右，中文摘要300字左右，并翻译成英文，关键词3-5个。
- 6、毕业论文查重报告的复制或者重复率不能高于30%。

指导教师签字： 日期：2026年4月20日

摘 要

随着电动汽车市场的快速发展，销售行业积累了涵盖产品属性、客户特征、交易信息等多维度的海量数据，传统数据处理方式难以对其进行高效分析和深度挖掘。

本文构建了基于Hive+Spark的大数据分析平台，实现了从数据采集、存储、处理、分析到可视化展示的完整流程。在数据处理层面，设计了ODS、DWD、DWS、DM四层数据仓库架构，通过Spark SQL编写数据清洗、多维度聚合与指标生成程序，将处理结果存储至Hive各分层表中，生成覆盖销售趋势、客户特征、产品特性、利润过户四个方向的15张指标分析表。在数据分析层面，利用Python结合scikit-learn、statsmodels等机器学习库，开展K-Means聚类、随机森林特征重要性分析和ARIMA时间序列预测等深度挖掘，并通过FineBI制作交互式仪表盘实现可视化展示。

研究结果表明，基于Hive+Spark的大数据技术能够高效处理海量汽车销售数据，所构建的分析方法和流程为汽车销售企业提供了精准的市场洞察与决策支持，对行业数字化转型具有实践参考价值。

关键词：Hive；Spark SQL；数据仓库；汽车销售；数据挖掘

Abstract

With the rapid development of the electric vehicle market, the sales industry has accumulated massive multi-dimensional data covering product attributes, customer characteristics, and transaction information. Traditional data processing methods are insufficient for efficient analysis and in-depth mining of such data.

This paper constructs a big data analysis platform based on Hive+Spark, implementing a complete workflow from data collection storage, processing, and analysis to visualization. At the data processing level, a four-layer data warehouse architecture comprising ODS, DWD, DWS, and DM is designed. Data cleaning, multi-dimensional aggregation, and indicator generation programs are developed using Spark SQL, with the results stored in the hierarchical tables of the Hive data warehouse, producing 15 indicator analysis tables across four analytical directions: sales trends, customer characteristics, product features, and profit-transfer analysis. At the data analysis level, Python is employed in conjunction with machine learning libraries such as scikit-learn and statsmodels to conduct in-depth mining, including K-Means clustering, Random Forest feature importance analysis, and ARIMA time series forecasting. Interactive dashboards are created using FineBI for visual presentation of the analytical results.

The results demonstrate that big data technology based on Hive+Spark can efficiently process massive automotive sales data. The analytical methods and workflow constructed in this study provide

accurate market insights and decision support for automotive sales enterprises, offering practical reference value for the digital transformation of the industry.

Key words: Hive; Spark SQL; Data Warehouse; Automotive Sales; Data Mining

目 录

1 绪论1

1.1 研究背景与意义1

1.1.1 研究背景1

1.1.2 研究目的1

1.1.3 研究意义1

1.2 国内外研究现状2

1.3 主要研究内容与技术路线2

2 核心技术与工具基础4

2.1 Hadoop分布式存储技术4

2.2 Hive数据仓库技术4

2.3 Spark SQL数据处理框架4

2.4 数据采集与传输工具5

2.5 数据库技术5

2.6 数据分析工具5

2.7 FineBI可视化工具6

2.8 本章小结6

3 需求分析与可行性论证7

3.1 特色分析需求7

3.2 数据需求分析7

3.3 技术需求分析7

3.4 可行性论证8

3.4.1 技术可行性8

3.4.2 数据可行性8

3.5 本章小结8

4 数据采集与预处理9

4.1 数据来源说明9

4.2 数据预处理9

4.3 数据采集实现过程10

4.4 核心字段说明11

4.5 数据库存储与数据导入流程12

4.6 本章小结	13
5 数据存储处理与特色分析	14
5.1 环境搭建与配置	14
5.2 数据仓库构建	15
5.3 数据分层处理	17
5.3.1 DWD层数据清洗与格式校验	17
5.3.2 DWS层数据聚合	20
5.3.3 DM层衍生指标生成	22
5.4 特色数据分析	25
5.4.1 销售趋势分析与预测	25
5.4.2 客户细分与价值分析	27
5.4.3 产品特征分析	28
5.4.4 利润预测与过户分析	30
5.4.5 综合关联分析与主成分分析	32
5.5 本章小结	34
6 可视化设计与实现	35
6.1 可视化工具选型与数据接入	35
6.2 特色图表设计思路	37
6.3 交互式仪表盘功能实现	45
6.4 本章小结	46
7 总结与展望	47
7.1 研究成果总结	47
7.2 研究不足	47
7.3 未来优化方向	48
参考文献	49
致 谢	50

1 绪论

1.1 研究背景与意义

1.1.1 研究背景

数字化新能源时代，电动汽车产业蓬勃发展，是全球汽车行业转型升级的重要方向。电动汽车市场的扩大使得销售企业拥有了大量的销售数据，客户数据、市场数据等。销售数据含有大量信息，对于企业制定销售策略、预测销售趋势、了解客户需求和合理布局市场，具有十分重要的价值。传统的数据处理方法面对如此大规模、多维度的数据，有其一定的局限性，一方面，传统数据处理方法的效率很低，难以在合理的时间内完成大量数据的分析和处

理；另一方面，传统数据处理方法的扩展性不足，随着数据量不断增长，难以应对深度数据挖掘和复杂分析。随着大数据技术的发展，Hadoop作为一种分布式计算平台，有着很强的存储和计算能力。Hive运行于Hadoop平台，具有结构化的查询分析能力。Spark基于内存计算，具有复杂数据分析能力。DataX（阿里巴巴开源离线数据同步工具）可以实现多种异构数据源之间的高效传输和整合，这些技术均为汽车销售数据分析提供了技术支撑。如何利用大数据技术对汽车销售数据进行深度分析，这是行业亟需解决的问题。

1.1.2 研究目的

本选题旨在运用大数据技术，构建一套完整的汽车销售数据分析平台，对海量汽车销售数据进行全面、深入的分析和挖掘。具体目的如下：

（1）挖掘销售趋势：通过对不同地区、不同车型的销量数据进行分析，把握销售数量的月度、季度、年度变化趋势，找出销售高峰与低谷的关联因素，为企业制定生产和销售计划提供依据。

（2）洞察客户需求：结合客户年龄、性别、职业等信息，分析不同客户群体的购车偏好，找出影响购买决策的关键因素，进行精准营销。

（3）优化市场策略：对比不同品牌的市场份额、售价等数据，分析企业的竞争优劣势，为制定市场策略提供参考。

（4）探索数据分析方法流程：总结适用于汽车销售行业的数据分析方法和流程，为行业内其他企业提供可借鉴的经验。

1.1.3 研究意义

（1）学术价值：选题应用大数据技术、数据分析算法、数据可视化技术，对汽车销售数据进行研究，包括数据收集、数据存储、数据处理、数据分析与可视化等，通过对所应用的技术及方法的创新，可丰富大数据在汽车销售领域的应用研究，为汽车销售领域的学术研究提供研究思路和方法。

（2）实践价值：汽车销售企业通过本选题的研究结果可以有效指导汽车销售企业的发展。通过数据分析平台可以获取销售趋势、客户需求和市场趋势等信息，为企业生产、销售、营销等决策提供依据。例如，企业可以根据销售趋势分析结果安排生产计划，根据客户需求分析结果进行产品设计和营销计划、根据市场竞争分析结果调整策略提升竞争力等。并且，所使用的数据分析方法具有通用性和可复制性，可推动汽车销售行业的数字化转型和可持续发展。

1.2 国内外研究现状

电动汽车产业发展的快速增长，市场规模不断扩大，销售数据表现“高增长+高复杂”现象。张蓉[1]指出电动汽车及“车电”销售的“快增”格局已对传统成品油的销售格局产生了冲击；郭梓云[2]指出电动汽车市场仍在扩大，行业统计数据显示，2023年1—11月我国新能源汽车销量830.4万辆，同比增长36.74%[3]。吴剑飞等[4]指出可以借助大数据提升汽车销售分析效率及决策能力，为行业数据研究提供方法参考。数据采集与预处理是开展销售分析的基础。高小杰[5]基于销售大数据挖掘消费者偏好，同时研究思路也体现出对多平台、多源销售数据的获取和处理需求；冯秀秀[6]从营销策略研究出发，进一步指出数据分析结果要服务于产品、价格、渠道、促销等。Huang S等[7]，通过网络爬虫获取车型参数及销售数据，结合清洗流程，处理数据失真与缺失；崔想[8]与车企合作获取一手销售与盈利数据，使研究更加接近真实业务。同时，刘柯[9]将电动汽车销售与相关外部要素结合，为后续的模式

与机制分析提供了完整数据。

在深度分析和预测方面，Huang S等[7]在中国市场的实证研究发现关键技术配置对纯电动汽车销量有显著影响，说明技术参数组合与市场表现有关。预测建模方面，Mishra DR等[10]提出LSTM-GBRT混合模型用于电动汽车销量的预测分析，证明了融合模型在复杂时序的预测效果；胡光川[11]在DBSCAN算法框架下构建汽车销售分析系统，揭示了聚类方法对客户细分和销售分析的可行性；过户与流通联系关系研究逐渐受到关注，葛卓然[12]从消费者转售焦虑视角提出保值率预期影响购买决策，销售研究需要更多关注“新车销售—二手流通”的联动关系。在政策与基础设施机制方面，刘柯[9]从政府补贴和充电站投资决策角度论证了政策工具扩散的作用机制；赵明奎等[13]提出充电站低成本建设路径，强调布局设计和设施选择对运营收益的重要性；杨文明[14]提出智能电动汽车销售和售后能力将向数字化、全渠道和全生命周期运营迈进；张琪[15]从补贴政策差异视角研究制造商共享模式选择，说明政策结构影响企业策略和市场表现。

可视化是最能体现分析成果的落地环节。通过FineBI的交互式仪表盘设计柱状图、饼图等图表，并且支持多层次筛选，Huang S等[7]利用可视化图表将复杂的数据直观呈现给企业，为企业决策提供有效支撑。

1.3 主要研究内容与技术路线

(1) 研究内容

①数据获取与数据预处理：基于和鲸社区（Heywhale）公布的电动汽车数据表数据集，包括电动汽车销售、客户信息、市场趋势数据，其中汽车品牌（汽车销量）、汽车销量（用户年龄）、市场份额指标为核心字段，编写Shell脚本和DataX工具进行自动化采集数据及传输，并清洗、转换、聚合数据，为后续分析提供数据基础。

②大数据技术操作：将数据预处理至MySQL数据库，进而通过Shell脚本和DataX工具导入HDFS，构建分布式存储环境。在Hive中建立数据仓库，设计合理的表结构和索引，使用SparkSQL进行数据清洗、转换、聚合，针对销售趋势、客户需求、市场竞争等分析方向编写复杂的查询语句进行深度分析，最后导出数据。

③数据显示与展示：通过FineBI工具设计交互式仪表盘，根据分析需求设计柱状图、饼图、折线图，城市、时间、车型等多种图表，从而实现城市、时间、车型等多种方向的选择，提升用户的体验和决策支持能力。

④数据集成与测试：将整个流程融合在一起，实现全流程的自动化。测试指标导入完整性、数据清洗质量要求，以及测试结果要求的优化。

(2) 技术路线

本项目采用的技术路线如图1.1所示：数据采集层（从和鲸社区（Heywhale）电动汽车数据表数据集获取数据）→数据存储层（MySQL存储原始数据→DataX导入至HDFS）→数据处理层（Hive数据仓库分层处理生成衍生指标）→数据分析层（基于核心字段编写Spark SQL查询语句开展深度分析→结果回存MySQL数据库）→可视化展示层（FineBI制作交互式仪表盘）→数据挖掘分析层（Python算法分析）。





图1.1 项目整体架构图

2 核心技术与工具基础

2.1 Hadoop分布式存储技术

Hadoop是Apache基金会开发的一个分布式系统，用户可以不知道分布式底层的情况下开发分布式程序。Hadoop中实现了分布式文件系统HDFS（Hadoop Distributed File System），具有高容错性和高吞吐量的特点，适合大数据的存储和访问。Hadoop生态系统包括HDFS、MapReduce、YARN、Hive、HBase等组成的大数据处理平台。本文中，使用底层的分布式存储系统用来持续化存储汽车销售数据，并使用上层的Hive数据仓库和Spark SQL计算引擎访问数据。

2.2 Hive数据仓库技术

Hive是基于Hadoop的数据仓库工具，可将结构化数据文件映射为数据库表，并提供类SQL查询功能（HQL）。HQL能将SQL语句转换为MapReduce任务运行，极大简化了大数据开发工作。Hive适合大规模数据的统计分析，不适用于联机事务处理和频繁修改操作的场景。

Hive架构主要包括：用户接口（CLI、Client、WebInterface）、元数据存储（通常使用MySQL存储表名、字段、权限等信息）、解释器/编译器/优化器/执行器、HDFS数据存储层以及MapReduce执行引擎。在本研究中，Hive用于构建数据仓库的分层表结构（ODS层、DWD层、DWS层、DM层），实现数据的结构化存储、查询与维护。

2.3 Spark SQL数据处理框架

Apache Spark是针对大规模数据处理的快速计算引擎，采用内存计算，在迭代计算和交互式查询的特性上显著的性能优势，可以部署在Hadoop YARN平台上。Spark SQL是Spark中处理结构化数据的核心模块，可以使用标准的SQL语句对结构化数据进行查询操作。Spark SQL和Hive的耦合是本方案的核心。Spark SQL接入Hive Metastore获得数据库、表结构等元数据，Spark中创建的数据库和表都可以由Hive直接识别和查询，主要包括：

(1) 元数据共享: Spark SQL连接Hive Metastore获得数据库、表结构等元数据,并将其与Hive数据库、表结构共享,实现数据存储共享;

(2) 数据存储共享: 在HDFS上存储HDFS上的数据,数据以和Hive数据相同的形式存储,例如TEXTFILE,可以配置字段分隔符和压缩编码;

(3) SQL执行引擎替换: Spark将HQL替换为RDD执行计划,将结构化数据运用内存计算、DAG优化提高了执行效率。

在本研究中,使用IntelliJ IDEA作为开发环境,基于Scala语言编写Spark SQL程序,项目包路径为com.masu.sql。程序通过SparkSession.builder()创建运行环境,配置enableHiveSupport()开启Hive支持后,使用ss.sql()方法执行SQL语句,实现对Hive数据仓库的直接操作。具体编写了3个独立的Scala程序,分别对应数据仓库的三个处理层级:

(1) dwd_electric_car_info程序: 负责DWD层数据清洗,通过CAST函数进行数据类型标准化,结合WHERE子句和RLIKE正则表达式过滤脏数据;

(2) dws_electriccarmonth_agg程序: 负责DWS层数据聚合,按月份、产地、品牌等多维度执行GROUP BY聚合,计算SUM、AVG、COUNT等基础统计指标;

(3) dm_electric_car_analysis程序: 负责DM层指标生成,运用窗口函数(RANK/OVER/PARTITION BY)、公用表表达式(WITH...AS)、条件分支(CASE WHEN)、嵌套子查询和LEFT JOIN关联等高级SQL语法,生成15张指标分析表。

2.4 数据采集与传输工具

DataX为阿里巴巴开源的离线数据同步工具,支持MySQL、HDFS、Hive等数据源之间的数据传输,DataX通过Framework+Plugin的结构设计,Reader插件读取源数据,Channel传输到Writer插件写入目标端,以实现数据的高效可靠传输。其中DataX可以完成两个数据的传输任务:将MySQL中的原始数据导入HDFS,将Hive DM层分析结果导入MySQL,给FineBI可视化工具连接查询。Shell脚本用于写自动化数据采集和任务调度脚本,实现数据采集、DataX任务执行、Spark作业提交的自动化串联,数据处理过程的一致性。

2.5 数据库技术

MySQL是本研究使用的关系型数据库管理系统,在系统中承担多重角色:一是作为Hive Metastore的后端存储,保存Hive数据仓库的元数据信息(数据库、表结构、分区等);二是作为原始数据的初步存储管理平台,在数据导入HDFS前进行初步管理;三是作为分析结果的最终存储库,接收从Hive DM层导出的指标数据,供可视化工具连接使用。

2.6 数据分析工具

在完成数据仓库的构建后,本研究利用Python语言,并结合scikit-learn、statsmodels以及Prophet等数据分析库,对导出的指标数据进行了深入的分析与挖掘。从实践角度来看,整个分析过程主要采用了以下几种方法:

(1) 首先应用K-Means聚类算法,对产品进行聚类并实现客户群体的细分;

(2) 随机森林算法则被用于评估特征的重要性,并在此基础上构建预测模型;

(3) 为形成对比和互补,将梯度提升算法引入到预测任务中;

(4) 面对多维度的复杂数据，主成分分析（PCA）是一种有效的降维手段；

(5) 在时间序列预测方面，Prophet模型和传统的ARIMA模型都得到了应用；

(6) 模型的评估工作则依赖于轮廓系数、均方误差和决定系数等一系列指标。

就开发环境而言，本研究选择IntelliJ IDEA作为集成开发环境，使用Scala语言编写Spark SQL程序，并通过Maven来统一管理项目的各项依赖。

2.7 FineBI可视化工具

FineBI是帆软公司的一款商业智能分析工具，可以通过拖拽的方式生成交互式数据分析仪表盘。FineBI可以直接将MySQL数据库中的关系数据输入，以图表的形式展现分析结果，支持柱状图、饼图、折线图、地图等可视化组件，并且支持多维筛选和动态交互。将MySQL数据库中DM层指标数据接入，即可生成汽车销售数据分析的交互式仪表盘。

2.8 本章小结

本章分别介绍了本研究涉及的Hadoop分布式存储、Hive数据仓库、Spark SQL数据处理框架、DataX数据传输工具、MySQL数据库、Python数据分析工具和FineBI可视化工具，所有的技术工具相互配合，共同支撑本研究的从数据获取、存储、处理、分析到可视化展示的整体技术，为后续的各章需求分析、系统实现、数据分析奠定技术基础。

3 需求分析与可行性论证

3.1 特色分析需求

基于汽车销售行业的实际业务场景，本研究确定了以下特色分析方向：

(1) 销售趋势分析：分析汽车销售的月度、季度、年度趋势，识别季节性规律，帮助企业了解市场动态，预测未来销售情况。

(2) 客户综合分析：通过分析客户的年龄、性别、职业、购买偏好等信息，了解不同客户群体的特点和需求，进行客户细分和精准营销。

(3) 产品特征分析：分析续航里程、电池容量、价格区间、驱动形式、智能化水平、充电效率等产品特征对销售的影响，为产品优化提供数据支撑。

(4) 利润过户分析：分析不同品牌、产品的利润构成和利润率，以及二手车过户情况，帮助企业优化定价策略。

(5) 综合分析：整合各分析方向的结果，进行跨维度关联分析，生成综合性的业务洞察。

上述分析方向的确定参考了吴剑飞等[4]提出的大数据技术在汽车销售数据分析中的应用框架，并结合高小杰[5]和胡光川[11]的研究成果进行了扩展。

3.2 数据需求分析

系统需要处理的数据包括：销售数据（品牌、车型、销量、销售额、时间等）、客户数据（年龄、性别、职业、位置等）、产品数据（续航里程、电池容量、价格、驱动形式、智能化、充电等）、市场数据（市场份额、产地等）、利润数据（成本、收益、利润率等）。这些数据数量大、数据类型多、数据时效性强、质量要求高，需要运用大数据处理技术进行数据存储。

3.3 技术需求分析

基于上述分析需求，系统在技术层面需要满足以下要求：

(1) 数据采集能力：从和鲸社区（Heywhale）电动汽车数据表数据集高效采集数据，并自动化导入大数据平台。

(2) 海量存储能力：能够存储大规模汽车销售数据，并支持高效的结构化查询。

(3) 数据处理能力：支持数据清洗、类型转换、多维度聚合等预处理操作，以及复杂SQL查询分析。

(4) 可视化展示能力：提供丰富的图表展示和多维度交互筛选功能，将分析结果直观呈现。

3.4 可行性论证

3.4.1 技术可行性

本研究所用的技术栈均是成熟且广泛使用的开源工具。Hadoop生态系统拥有稳定的分布式存储和计算功能，目前已得到了广泛应用；Hive作为主流的数据仓库工具，能够对结构化的数据进行管理并进行SQL查询；Spark SQL能够处理大量的数据，对数据的聚合工作可以在Spark SQL上有较好的实现；DataX作为数据同步工具，能够有效地进行MySQL和HDFS之间的数据传输；FIBI是可视化组件和交互功能的完整体。以上工具之间具有良好的兼容性和集成能力，可以满足本研究从采集到可视化展示的全部需求。IntelliJ IDEA作为一个集成环境，结合Maven项目管理工具，可以有效地完成Spark SQL程序的开发、调试和部署。

3.4.2 数据可行性

本研究的数据来源于和鲸社区（Heywhale）公开发布的电动汽车统计结果表数据集。该数据集涵盖的字段十分全面，包括汽车品牌、销量、产量、售价、利润、电池容量、续航里程、用户年龄、用户性别、用户职业、驱动形式、充电效率、智能化水平以及过户状态等核心信息。从实践角度来看，这些丰富且完整的字段能够很好地支撑本研究在销售趋势分析、客户特征画像、产品特性比较以及利润与过户关系探讨等多个方向的研究需求。总体而言，这份数据源可靠，字段齐全，为后续的分析工作奠定了坚实的信息基础。

3.5 本章小结

本章从特色分析需求、数据需求和技术需求三个方面进行了全面的需求分析，并从技术可行性和数据可行性两个维度开展了论证。分析结果表明，现有技术工具能够有效支撑本研究的全部分析需求，数据源可靠且字段齐全，项目实施具有充分的可行性，为后续的数据采集、处理和分析工作奠定了基础。

4 数据采集与预处理

4.1 数据来源说明

本文采用的数据来源于和鲸社区（Heywhale）公开发布的电动汽车数据表，包含了电动汽车销售、客户信息、市场趋势等数据，以Excel（.xlsx）形式发布，其上记录了不同品牌、不同地区，不同时间段汽车的销售数据，数据规模基本满足大数据分析的要求。该数据采用结构化表格格式存储，每条记录为一次销售交易的完整信息，包括了产品特征、客户信息、交易信息以及市场指标等，和高小杰[5]从多平台获取电动汽车销量与参数数据的研究思路相同，具有客观性和可靠性。

4.2 数据预处理

原始数据从和鲸社区获得，以Excel形式（.xlsx）存储，共10.6万条记录。导入MySQL之前，参照Huang S等[7]的清洗思路对原始数据进行预处理：

(1) 在数据预处理阶段，首先处理了缺失值。对于品牌、产地、销量和售价等核心字段，缺失的记录被补全或

直接剔除；而对于那些非关键字段，则统一用空字符串填充，以满足数据库表的NOT NULL约束要求。

(2) 数据格式的标准化工作。通过将所有生产日期统一转换为“YYYY-MM”格式，这为后续的时间序列分析提供了便利。同时，所有中文字段均被统一编码为UTF-8格式，有效避免了潜在的乱码问题。

(3) 数据类型校验是确保数据质量的关键一步。根据目标表的结构定义，对各字段进行了严格的类型转换：销量、产量等字段被校验为INT类型；原价、售价和利润等字段则被设定为DECIMAL类型。特别地，电池容量和续航里程采用了DECIMAL(10, 2)的精度。市场份额字段则使用了DECIMAL(20, 7)以确保高精度计算的需求。这一系列操作保证了整个数据集在数值精度上的一致性。

(4) 异常值的筛查与处理同样重要，我们对所有数值型字段进行了合理性检查，识别出诸如销量为负值、售价为零或负数、以及年龄超出合理范围等异常记录。这些记录随后被修正或从数据集中剔除。

(5) 由于原始数据缺乏唯一标识符，我们在建表时通过设置id字段的AUTO_INCREMENT约束来自动生成主键。这一设计确保了每一条记录都具有可追溯的唯一标识。

完成上述清洗步骤后，再利用Navicat的导入向导功能，将处理好的数据导入到MySQL数据库的electric_car_sales表中。在此过程中，仔细完成了源数据字段与目标表结构的映射及类型匹配。最终成功入库约10.6万条有效记录，涵盖22个字段，为后续大数据平台的接入与分析工作奠定了规范、可靠的数据基础。


4.3 数据采集实现过程

数据采集通过Shell脚本和DataX任务完成。首先将原始数据文件拷贝到MySQL数据库中进行存储和管理如图4.1所示。编写DataX的JSON配置文件，配置MySQL Reader插件和HDFS Writer插件，设置源端与数据库连接、查询SQL、目标端HDFS路径和文件格式，配置Shell自动化脚本，将数据从MySQL上传到HDFS中，如图4.2所示。Shell脚本将整个采集过程串联，通过定时调度实现采集任务自动化运行，保证数据完整。接入HDFS如图4.3所示，在Hive中打开ODS层原始数据表，将HDFS上的数据文件转换到Hive表中。

```
mysql> use electric_car_sales;
Reading table information for completion of table and column names
You can turn off this feature to get a quicker startup with -A

Database changed
mysql> show tables;
+-----+
| Tables_in_electric_car_sales |
+-----+
| electric_car_sales            |
+-----+
1 row in set (0.00 sec)
```

图4.1 原始数据表



```
rwXr-xr-x. 1 root root 1200 9月 15 17:13 e_commerce_mysql_to_hdfs.sh
rwXr-xr-x. 1 root root 112 9月 17 16:04 e_commerce_ods_to_dwd.sh
rwXr-xr-x. 1 root root 409 1月 7 14:39 electric_car_sale_dm.sh
rwXr-xr-x. 1 root root 1982 1月 8 10:31 electric_car_sale_hdfs_to_mysql.sh
rwXr-xr-x. 1 root root 833 1月 6 12:45 electric_car_sale_mysql_to_hdfs.sh
[root@hadoop01 bin] # electric_car_sale_mysql_to_hdfs.sh all
导入表格数据/export/servers/datax/job/electric_car_sale/import/electric_car_sale
s.json
[root@hadoop01 bin] #
```

图4.2 SHELL脚本自动化




图4.3 表数据上传HDFS

4.4 核心字段说明

数据集涵盖了22个核心字段，具体如表4.1所示，包括id（记录编号）、brand（汽车品牌）、origin（产地）、sales_volume（销量）、production_volume（产量）、production_date（生产日期）、original_price（原价）、sale_price（售价）、profit（利润）、battery_capacity_kwh（电池容量）、range_nedc_cltc（续航里程）、user_age（用户年龄）、user_gender（用户性别）、user_occupation（用户职业）、drive_type（驱动形式）、charging_efficiency（充电效率）、intelligence_level（智能化水平）、transfer_status（过户状态）等。这些字段从产品属性、客户特征、交易信息和市场指标等多个维度构建了信息基础。就本研究而言，这样的结构设计能够较好地支撑后续对销售趋势、客户需求、产品特性以及利润与过户关系等多方面的分析工作。表数据的具体示例如图4.4所示。

表4.1 MySQL原始数据表字段结构（electric_car_sales）

字段名	数据类型	说明
id	INT NOT NULL AUTO_INCREMENT	记录编号（主键）
brand	VARCHAR(255)	汽车品牌
origin	VARCHAR(255)	产地
production_volume	INT	产量
sales_volume	INT	销量

operating_kilometers	DECIMAL(15, 0)	运行公里数
production_date	VARCHAR(255)	生产日期（YYYY-MM）
member_level	VARCHAR(255)	会员级别
original_price	DECIMAL(15, 0)	原价
sale_price	DECIMAL(15, 0)	售价
profit	DECIMAL(15, 0)	利润
transfer_status	VARCHAR(255)	过户状态
manufacturer	VARCHAR(255)	厂商

续表4.1

字段名	数据类型	说明
battery_capacity_kwh	DECIMAL(10, 2)	电池容量（kWh）
range_nedc_cltc	DECIMAL(10, 2)	续航里程（NEDC/CLTC）
charging_efficiency	VARCHAR(255)	充电效率
drive_type	VARCHAR(255)	驱动形式
market_share	DECIMAL(20, 7)	市场份额
user_age	INT	用户年龄
user_gender	VARCHAR(255)	用户性别
user_occupation	VARCHAR(255)	用户职业
user_habits	VARCHAR(255)	用户使用习惯
intelligence_level	VARCHAR(255)	智能化水平

```
[root@hadoop01 bin]# hadoop fs -cat /electric_car_sales/car_sales/electric_car_sales__f72f6040_6cef_48fe_8fe5_00e27c3i
| gzip -d | head - 5
1  小鹏汽车      江苏      756      220      231.74  2019-04  银牌会员      542337.44      541172.28      -1165.
  已过户两次    小鹏汽车_江苏  70.917    96.288  快充      四驱      0.000017099331571584  54      男      自由职
/隔天
2  哪吒汽车      上海      8296     2708     46663.66      2020-05  普通会员161793.53      170831.19      9037.4
  哪吒汽车_上海  59.399    78.518  慢充      前驱      0.000210477226799316  51      女      医生      45公里/隔天      L4/每4
3  奥迪      安徽      1444     107      21652.96      2020-01  普通会员      307628.84      311977.64      4348.8
  一次          奥迪_安徽      78.337    106.188  慢充      后驱      0.000008316493082543  59      女      蓝领      92公里/每天
年
4  小鹏汽车      江西      6137     4031     32248.46      2019-08  普通会员239516.22      205939.57      -33576
```

图4.4 使用cat查看数据

4.5 数据库存储与数据导入流程

原始数据首先被存入MySQL统计结果库，如图4.5所示，以进行初步的管理与组织。在MySQL中，创建对应的数据表，并仔细定义了每个字段的统计结果类型和约束条件，随后通过批量导入语句将原始统计结果加载至数据库。当数据在MySQL中完成了基本的完整性检查后，便进入下一阶段。利用DataX工具来执行数据传输任务。

整个数据导入流程遵循一条清晰的路径：从MySQL（作为原始统计结果存储）出发，经由DataX（负责信息传

输），到达HDFS（实现分布式存储），最终映射到Hive的ODS层（形成外部表）。在配置DataX任务时，我们在配置文件中明确指定了源表和目标表之间的字段映射关系、采用制表符'\t'作为统计结果分隔符，并设定了目标HDFS路径。这些设置对于确保资料在传输过程中格式的一致性至关重要，当信息成功导入HDFS后，我们在Hive中执行CREATE EXTERNAL TABLE语句来创建ODS层的外部表。该语句会指定统计结果在HDFS上的具体存储位置和字段分隔符。便于Hive便能直接读取HDFS上的原始资料文件，从而实现了从传统关系型数据库到大数据平台的平滑、无缝接入。

id	brand	origin	production_volume	sales_volume	operating_kilometers	production_date	member_level	original_price	sale_price	profit
1	小鹏汽车	江苏	756	220	232	2019-04	银牌会员	542337	541172	
2	哪吒汽车	上海	8296	2708	46664	2020-05	普通会员	161794	170831	
3	奥迪	安徽	1444	107	21653	2020-01	普通会员	307629	311978	
4	小鹏汽车	江西	6137	4031	32248	2019-08	普通会员	239516	205940	
5	特斯拉	江苏	1661	870	66484	2017-06	金牌会员	810776	816104	
6	雷克萨斯	江西	7322	4917	33531	2016-02	金牌会员	932095	982710	
7	比亚迪	北京	4748	2063	2705	2019-02	普通会员	200997	162004	
8	宝马	北京	2294	513	31565	2019-05	普通会员	155138	124407	
9	特斯拉	深圳	374	252	9884	2023-05	金牌会员	889214	942804	
10	雷克萨斯	浙江	4617	2781	12498	2021-05	普通会员	310310	372293	
11	蔚来	安徽	6619	1700	64500	2016-07	银牌会员	501519	528307	
12	丰田	深圳	9089	1653	4869	2024-08	银牌会员	796330	761483	

图4.5 MYSQL中数据表

4.6 本章小结

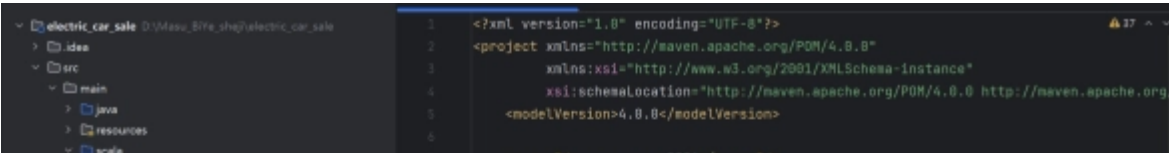
本章介绍了数据采集与数据预处理的流程，分为数据来源介绍、数据预处理、数据采集实现、数据字段描述、数据库存储操作与数据导入。首先对从和鲸社区获取的Excel数据进行缺失值处理、格式标准化、类型校验、异常值处理等预处理操作，将原始EXCEL数据约10.6万条导入MySQL数据库，再通过Shell脚本和DataX工具实现MySQL到Hive ODS层的自动化数据接入，为后续进行数据仓库分层处理和分析提供数据支撑。

5 数据存储处理与特色分析

5.1 环境搭建与配置

系统环境搭建主要包括以下组件的安装和配置：

- (1) Hadoop环境：安装HDFS和YARN，配置集群参数，确保分布式存储和资源管理功能正常运行。
- (2) Hive环境：安装Hive，配置元数据存储（使用MySQL作为Metastore后端），设置HDFS数据存储路径，确保Hive能够正常创建数据库和表，并通过HQL查询HDFS上的数据。
- (3) Spark环境：安装Spark，配置与Hadoop和Hive的集成。将Hive的hive-site.xml配置文件复制到Spark的conf目录下，使Spark SQL能够通过Hive Metastore访问Hive中的数据库和表结构。
- (4) IDEA开发环境：安装IntelliJ IDEA集成开发环境，创建基于Maven的Scala项目。在pom.xml文件中配置Spark相关依赖如图5.1所示，主要包括：org.apache.spark:spark-core（Spark核心库，提供RDD等基础功能）、org.apache.spark:spark-sql（Spark SQL模块，提供DataFrame和SQL查询能力）、org.apache.spark:spark-hive（Spark Hive集成模块，提供对Hive数据仓库的读写支持）如图5.1所示。项目包路径为com.masu.sql，在IDEA中编写Scala程序，通过SparkSession.builder()创建Spark SQL运行环境，配置enableHiveSupport()开启Hive支持，即可在程序中使用ss.sql()方法执行SQL语句如图5.2所示。



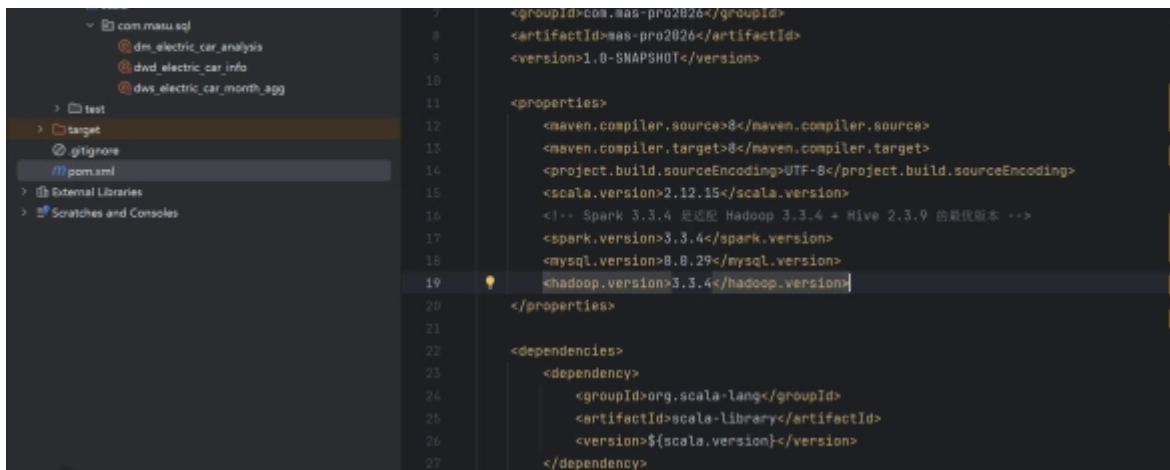


图5.1 Maven依赖

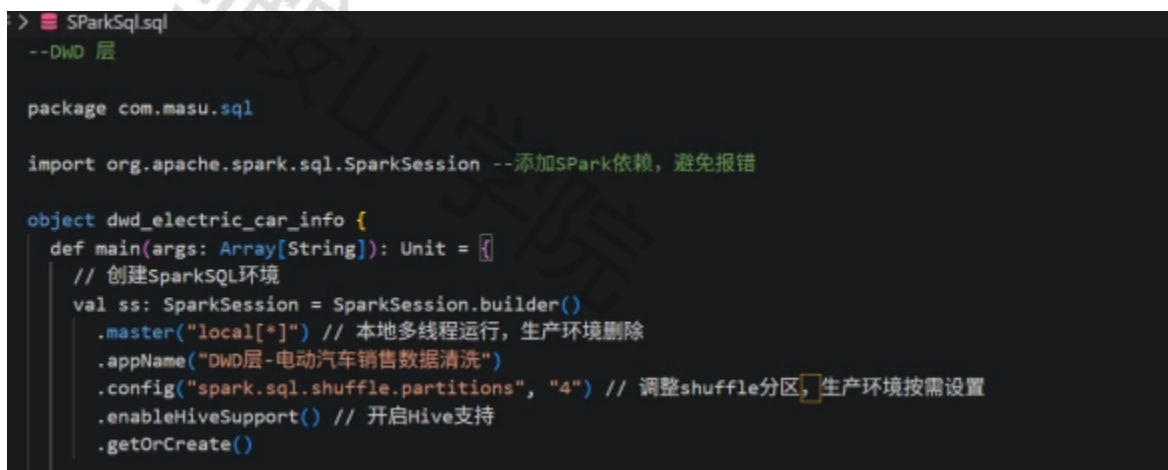


图5.2 Spark环境配置

(5) 数据导出环境：配置DataX工具，实现Hive数据仓库中DM层指标表数据向MySQL数据库的导出，供FineBI可视化工具连接查询。系统环境配置完成后，进行功能联调测试，确保数据能够从MySQL经DataX导入HDFS，通过Spark SQL处理后写入Hive，最终从Hive导出至MySQL，各环节协同工作正常。

5.2 数据仓库构建

数据仓库为分层设计，从底向上分为ODS层、DWD层、DWS层和DM层四层，如图5.3所示，Hive中为每层级创建数据库，通过CREATE DATABASE建立命名空间，由CREATE TABLE定义数据表，配置制表符分隔（'\t'）、TEXTFILE存储格式和GzipCodec压缩编码如图5.4所示。数据仓库中的表包括ODS层原始表（electric_car_sales）存储原始数据命令图5.5所示、DWD层明细表（dwd_electric_car_info）存储清洗后的标准化数据，22个字段，采用标准数据BIGINT、STRING、DECIMAL等、DWS层聚合表（dws_electric_car_month_agg）、DM层15张指标分析表。



图5.3 Hive数仓架构图

```

原始表:
DROP TABLE IF EXISTS electric_car_sales;

CREATE TABLE electric_car_sales (
  id bigint COMMENT '唯一标识ID',
  brand string COMMENT '电动汽车品牌',
  origin string COMMENT '电动汽车产地',
  production_volume bigint COMMENT '电动汽车产量',
  sales_volume bigint COMMENT '电动汽车销量',
  operating_kilometers string COMMENT '电动汽车运行公里数',
  production_date string COMMENT '电动汽车生产日期',
  member_level string COMMENT '拥有者会员级别',
  original_price string COMMENT '电动汽车原价',
  sale_price string COMMENT '电动汽车售价',
  profit string COMMENT '电动汽车利润',
  transfer_status string COMMENT '电动汽车过户状态',
  manufacturer string COMMENT '电动汽车厂商',
  battery_capacity_kwh string COMMENT '电池容量(kWh)',
  range_nedc_cltc string COMMENT '续航里程(NEDC/CLTC)',
  charging_efficiency string COMMENT '充电效率',
  drive_type string COMMENT '驱动形式',
  market_share string COMMENT '市场份额',
  user_age bigint COMMENT '用户年龄',
  user_gender string COMMENT '用户性别',
  user_occupation string COMMENT '用户职业',
  user_habits string COMMENT '用户使用习惯',
  intelligence_level string COMMENT '电动汽车智能化水平'
)
COMMENT '电动汽车销售数据表'
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
STORED AS TEXTFILE
TBLPROPERTIES (
  'serialization.null.format='',
  'mapreduce.output.fileoutputformat.compress='true',
  'mapreduce.output.fileoutputformat.compress.codec='org.apache.hadoop.io.compress.GzipCodec'
)

```

图5.4 Hive原始表

```
hive load data命令进行导入:
load data inpath "/electric_car_sales/car_sales" overwrite into table electric_car_sales;
```

图5.5 HDFS数据传输Hive

5.3 数据分层处理

数据分层，通过IntelliJ IDEA中编写3个Spark SQL程序(dwd_electric_car_info、dws_electric_car_month_agg、dm_electric_car_analysis)，配合SparkSession生成运行环境并配置Hive，以ss.sql()方法执行SQL，从DWD→DWS→DM依次进行数据处理。

5.3.1 DWD层数据清洗与格式校验

DWD层数据清洗程序从ODS层原始表electric_car_sales中读取数据，先创建DWD层数据表如图5.6所示，创建好的字段如表5.1所示，紧接着执行以下清洗和校验操作：

表5.1 DWD层明细表字段结构（dwd_electric_car_info）

字段名	数据类型	说明
id	BIGINT	唯一标识ID
brand	STRING	电动汽车品牌
origin	STRING	电动汽车产地
production_volume	BIGINT	电动汽车产量
sales_volume	BIGINT	电动汽车销量
operating_kilometers	DECIMAL(15, 0)	运行公里数
production_date	STRING	生产日期（YYYY-MM）
member_level	STRING	会员级别
original_price	DECIMAL(15, 0)	原价
sale_price	DECIMAL(15, 0)	售价
profit	DECIMAL(15, 0)	利润
transfer_status	STRING	过户状态
manufacturer	STRING	厂商
battery_capacity_kwh	DECIMAL(10, 2)	电池容量（kWh）
range_nedc_cltc	DECIMAL(10, 2)	续航里程
charging_efficiency	STRING	充电效率
drive_type	STRING	驱动形式
market_share	DECIMAL(20, 7)	市场份额
user_age	BIGINT	用户年龄
user_gender	STRING	用户性别
user_occupation	STRING	用户职业
user_habits	STRING	用户使用习惯

(1) 数据类型标准化：使用CAST将原始字段转换为标准数据类型，如：销量转换成BIGINT、售价转换为DECIMAL(12, 2)、用户年龄转换为INT等，以保证数据的规范性。

(2) 格式校验和对脏数据过滤：在INSERT OVERWRITE中WHERE中设置生产日期非空且YYYY-MM格式(RLIKE正则表达式)、销量和产量大于等于0、原价和售价大于等于0、用户年龄18~100岁，不合格的脏数据（如非法日期、负数销量、异常年龄等）在清洗过程中被自动过滤，清洗后的数据通过INSERT OVERWRITE写入DWD层明细表如图5.7所示。

DWD层数据清洗主要SQL语句：

// 插入数据：从ODS层清洗后插入，做类型转换+脏数据过滤

```
INSERT OVERWRITE TABLE dwd_electric_car.dwd_electric_car_info
SELECT
CAST(id AS BIGINT) AS id,
brand,
origin,
    CAST(production_volume AS BIGINT) AS production_volume,
CAST(sales_volume AS BIGINT) AS sales_volume,
    CAST(operating_kilometers AS DECIMAL(15, 0)) AS operating_kilometers,
production_date,
member_level,
CAST(original_price AS DECIMAL(15, 0)) AS original_price,
CAST(sale_price AS DECIMAL(15, 0)) AS sale_price,
CAST(profit AS DECIMAL(15, 0)) AS profit,
transfer_status,
manufacturer,
    CAST(battery_capacity_kwh AS DECIMAL(10, 2)) AS battery_capacity_kwh,
CAST(range_nedc_cltc AS DECIMAL(10, 2)) AS range_nedc_cltc,
charging_efficiency,
drive_type,
    CAST(market_share AS DECIMAL(20, 7)) AS market_share,
CAST(user_age AS BIGINT) AS user_age,
user_gender,
user_occupation,
user_habits,
intelligence_level
```

```

FROM electric_car_sale.electric_car_sales
WHERE production_date IS NOT NULL
AND production_date RLIKE '^\\d{4}-\\d{2}$'
AND CAST(sales_volume AS BIGINT) >= 0
AND CAST(production_volume AS BIGINT) >= 0
AND CAST(original_price AS DECIMAL(15, 0)) >= 0
AND CAST(sale_price AS DECIMAL(15, 0)) >= 0
AND CAST(user_age AS BIGINT) BETWEEN 18 AND 100;

```

```

// 1. 创建DWD函数视图
ss.sql("CREATE DATABASE IF NOT EXISTS dwd_electric_car")

// 2. 建DWD明细表 (清洗后, 字段类型标准化)
ss.sql(
  """
  | CREATE TABLE IF NOT EXISTS dwd_electric_car.dwd_electric_car_info (
  |   id BIGINT COMMENT '唯一标识ID',
  |   brand STRING COMMENT '电动汽车品牌',
  |   origin STRING COMMENT '电动汽车产地',
  |   production_volume BIGINT COMMENT '电动汽车产量',
  |   sales_volume BIGINT COMMENT '电动汽车销量',
  |   operating_kilometers DECIMAL(15,0) COMMENT '电动汽车运行公里数',
  |   production_date STRING COMMENT '电动汽车生产日期(YYYY-MM)',
  |   member_level STRING COMMENT '拥有者会员级别',
  |   original_price DECIMAL(15,0) COMMENT '电动汽车原价',
  |   sale_price DECIMAL(15,0) COMMENT '电动汽车售价',
  |   profit DECIMAL(15,0) COMMENT '电动汽车利润',
  |   transfer_status STRING COMMENT '电动汽车过户状态',
  |   manufacturer STRING COMMENT '电动汽车厂商',
  |   battery_capacity_kwh DECIMAL(10,2) COMMENT '电池容量(kwh)',
  |   range_nedc_cltc DECIMAL(10,2) COMMENT '续航里程(NEDC/CLTC)',
  |   charging_efficiency STRING COMMENT '充电效率',
  |   drive_type STRING COMMENT '驱动形式',
  |   market_share DECIMAL(20,7) COMMENT '市场份额',
  |   user_age BIGINT COMMENT '用户年龄',
  |   user_gender STRING COMMENT '用户性别',
  |   user_occupation STRING COMMENT '用户职业',
  |   user_habits STRING COMMENT '用户使用习惯',
  |   intelligence_level STRING COMMENT '电动汽车智能化水平'
  | )
  | COMMENT 'DWD层-电动汽车销售清洗后明细表'
  """
)

```

图5.6 SParkSql: DWD层建表

```

// 3. 插入数据: 从ODS层清洗后插入, 做类型转换+脏数据过滤
ss.sql(
  """
  | INSERT OVERWRITE TABLE dwd_electric_car.dwd_electric_car_info
  | SELECT
  |   CAST(id AS BIGINT) AS id,
  |   brand,
  |   origin,
  |   CAST(production_volume AS BIGINT) AS production_volume,
  |   CAST(sales_volume AS BIGINT) AS sales_volume,
  |   CAST(operating_kilometers AS DECIMAL(15,0)) AS operating_kilometers,
  |   production_date,
  |   member_level,
  |   CAST(original_price AS DECIMAL(15,0)) AS original_price,
  |   CAST(sale_price AS DECIMAL(15,0)) AS sale_price,
  |   CAST(profit AS DECIMAL(15,0)) AS profit,
  |   transfer_status,
  |   manufacturer,
  |   CAST(battery_capacity_kwh AS DECIMAL(10,2)) AS battery_capacity_kwh,
  |   CAST(range_nedc_cltc AS DECIMAL(10,2)) AS range_nedc_cltc,
  |   charging_efficiency,
  |   drive_type,
  |   CAST(market_share AS DECIMAL(20,7)) AS market_share,
  |   CAST(user_age AS BIGINT) AS user_age,
  |   user_gender,
  |   user_occupation,
  |   user_habits,
  |   intelligence_level
  | FROM electric_car_sale.electric_car_sales
  | -- 脏数据过滤: 非空日期、销量/产量≥0、价格≥0、年龄18-100岁
  """
)

```



```
| WHERE production_date IS NOT NULL
| AND production_date RLIKE '^\\d{4}-\\d{2}$'
| AND CAST(sales_volume AS BIGINT) >= 0
| AND CAST(production_volume AS BIGINT) >= 0
| AND CAST(original_price AS DECIMAL(15,0)) >= 0
| AND CAST(sale_price AS DECIMAL(15,0)) >= 0
| AND CAST(user_age AS BIGINT) BETWEEN 18 AND 100;
|"".stripMargin)
```

图5.7 SParkSql：DWD层数据插入

5.3.2 DWS层数据聚合

DWS层聚合程序从DWD层明细表中读取清洗后的数据，按统计月份、产地、品牌、驱动形式、充电效率、智能化水平等多个维度进行GROUP BY聚合如图5.8所示。计算的基础聚合指标包括：月度总销量、月度总产量、售价总和、利润总和、客户数量、平均电池容量、平均续航里程等如表5.2所示。聚合结果写入DWS层月度聚合表dws_electric_car_month_agg，为DM层的深度分析提供基础数据支撑。

表5.2 DWS层聚合表字段结构（dws_electric_car_month_agg）

字段名	数据类型	说明
stat_month	STRING	统计月份（YYYY-MM）
origin	STRING	产地
brand	STRING	电动汽车品牌
drive_type	STRING	驱动形式
charging_efficiency	STRING	充电效率
intelligence_level	STRING	智能化水平
transfer_status	STRING	过户状态
battery_capacity_kwh	DECIMAL(10, 2)	电池容量（kWh）
range_nedc_cltc	DECIMAL(10, 2)	续航里程
user_age	BIGINT	用户年龄
user_gender	STRING	用户性别
user_occupation	STRING	用户职业
total_sales_volume	BIGINT	月度销量
total_production_volume	BIGINT	月度产量
total_original_price	DECIMAL(20, 2)	月度原价总和
total_sale_price	DECIMAL(20, 2)	月度售价总和
total_profit	DECIMAL(20, 2)	月度利润总和
total_market_share	DECIMAL(20, 7)	月度市场份额总和
customer_count	BIGINT	客户数量
avg_battery_capacity	DECIMAL(10, 2)	平均电池容量
avg_range_nedc	DECIMAL(10, 2)	平均续航里程

DWS层数据聚合核心SQL语句:

// 插入数据: 从DWD层按维度聚合, 计算基础指标

```
INSERT OVERWRITE TABLE dws_electric_car.dws_electric_car_month_agg
SELECT
production_date AS stat_month, -- 生产日期作为统计月份
origin,
brand,
drive_type,
charging_efficiency,
intelligence_level,
transfer_status,
battery_capacity_kwh,
range_nedc_cltc,
user_age,
user_gender,
user_occupation,
SUM(sales_volume) AS total_sales_volume,
SUM(production_volume) AS total_production_volume,
SUM(original_price) AS total_original_price,
SUM(sale_price) AS total_sale_price,
SUM(profit) AS total_profit,
SUM(market_share) AS total_market_share,
COUNT(DISTINCT id) AS customer_count, -- 按ID去重统计客户数
AVG(battery_capacity_kwh) AS avg_battery_capacity,
AVG(range_nedc_cltc) AS avg_range_nedc
FROM dwd_electric_car.dwd_electric_car_info
GROUP BY
production_date, origin, brand, drive_type, charging_efficiency,
intelligence_level, transfer_status, battery_capacity_kwh,
range_nedc_cltc, user_age, user_gender, user_occupation;
```

```
// 1. 创建DWS层数据库
ss.sql("CREATE DATABASE IF NOT EXISTS dws_electric_car")

// 2. 建DWS月度聚合表(核心维度: stat_month+origin+brand+产品特征)
ss.sql(
    """
    CREATE TABLE IF NOT EXISTS dws_electric_car.dws_electric_car_month_agg (
        stat_month STRING COMMENT '统计月份(YYYY-MM)',
    """
```

```

|   origin STRING COMMENT '产地',
|   brand STRING COMMENT '电动汽车品牌',
|   drive_type STRING COMMENT '驱动形式',
|   charging_efficiency STRING COMMENT '充电效率',
|   intelligence_level STRING COMMENT '智能化水平',
|   transfer_status STRING COMMENT '过户状态',
|   battery_capacity_kwh DECIMAL(10,2) COMMENT '电池容量(kwh)',
|   range_nedc_cltc DECIMAL(10,2) COMMENT '续航里程(NEDC/CLTC)',
|   user_age BIGINT COMMENT '用户年龄',
|   user_gender STRING COMMENT '用户性别',
|   user_occupation STRING COMMENT '用户职业',
|   total_sales_volume BIGINT COMMENT '月度销量',
|   total_production_volume BIGINT COMMENT '月度产量',
|   total_original_price DECIMAL(20,2) COMMENT '月度原价总和',
|   total_sale_price DECIMAL(20,2) COMMENT '月度售价总和',
|   total_profit DECIMAL(20,2) COMMENT '月度利润总和',
|   total_market_share DECIMAL(20,7) COMMENT '月度市场份额总和',
|   customer_count BIGINT COMMENT '客户数量',
|   avg_battery_capacity DECIMAL(10,2) COMMENT '平均电池容量',
|   avg_range_nedc DECIMAL(10,2) COMMENT '平均续航里程'
| )
| COMMENT 'DWS层-电动汽车销售月度基础聚合表'
| ROW FORMAT DELIMITED
| FIELDS TERMINATED BY '\t'
| STORED AS TEXTFILE

```

图5.8 SParkSql: DWS层建表

5.3.3 DM层衍生指标生成

DM层指标生成程序从DWS层聚合表中读取数据，先进行Spark的环境配置如图5.9所示，再利用Spark SQL的高级SQL语法，包括窗口函数（RANK/OVER/PARTITION BY）、公用表表达式（WITH...AS）、条件分支（CASE WHEN）、嵌套子查询等，生成15张指标分析表，如表5.3所示。这15张表覆盖了本研究的全部特色分析方向，具体包括：

表5.3 DM层15张指标分析表总览

表名	表描述	核心字段
dm_monthly_sales_trend	月度销售趋势分析表	stat_month, brand, total_sales_volume, total_production_volume, avg_sale_price, total_profit
dm_quarterly_sales_trend	季度销售趋势分析表	stat_quarter, brand, total_sales_volume, total_production_volume, avg_sale_price, total_profit
dm_yearly_sales_trend	年度销售趋势分析表	stat_year, brand, total_sales_volume, total_production_volume, avg_sale_price, total_profit
dm_region_sales_analysis	地区销售分析表	origin, brand, stat_month, total_sales_volume, avg_sale_price, market_share, sales_rank

dm_customer_age_analysis	客户年龄分析表	age_group, stat_month, customer_count, total_sales_volume, avg_purchase_price, preferred_brand
dm_customer_gender_analysis	客户性别分析表	user_gender, stat_month, customer_count, total_sales_volume, avg_purchase_price
dm_customer_occupation_analysis	客户职业分析表	user_occupation, stat_month, customer_count, total_sales_volume, avg_purchase_price, preferred_brand
dm_price_range_analysis	价格区间分析表	brand, price_range, stat_month, avg_profit_margin, total_profit
dm_battery_capacity_analysis	电池容量分析表	brand, battery_range, stat_month, avg_sale_price
dm_range_analysis	续航里程分析表	brand, range_category, stat_month, sales_volume, avg_battery_capacity,

续表5.3

表名	表描述	核心字段
dm_drive_type_analysis	驱动形式分析表	brand, drive_type, stat_month, sales_volume, avg_sale_price
dm_charging_efficiency_analysis	充电效率分析表	brand, charging_efficiency_range, stat_month, sales_volume, avg_sale_price
dm_intelligence_level_analysis	智能化水平分析表	brand, intelligence_level, stat_month, sales_volume, avg_sale_price, future_potential
dm_profit_analysis	利润分析表	brand, stat_month, total_revenue, total_cost, total_profit, profit_margin, profit_per_unit

		brand,	transfer_status,
dm_transfer_status_analysis	过户状态分析表	stat_month,	transfer_count,
		avg_transfer_price,	
		transfer_reason_analysis	

- (1) 销售趋势方向：月度销售趋势表、季度销售趋势表、年度销售趋势表、地区销售分析表；
- (2) 客户分析方向：客户年龄分析表、客户性别分析表、客户职业分析表；
- (3) 产品特征方向：价格区间分析表、电池容量分析表、续航里程分析表、驱动形式分析表、充电效率分析表、智能化水平分析表；
- (4) 利润过户方向：利润分析表、过户状态分析表。 各指标表生成后直接写入Hive的DM层数据库如图5.10所示，并通过DataX批量导出至MySQL，供后续的特色数据分析和可视化展示使用。

```
--DM 层
package com.masu.sql

import org.apache.spark.sql.SparkSession

object dm_electric_car_analysis {
  def main(args: Array[String]): Unit = {
    // 创建SparkSQL环境
    val ss: SparkSession = SparkSession.builder()
      .master("local[*]")
      .appName("DM层-电动汽车销售15张指标表生成")
      .config("spark.sql.shuffle.partitions", "8")
      .enableHiveSupport()
      .getOrCreate()

    // 1. 创建DM层数据库
    ss.sql("CREATE DATABASE IF NOT EXISTS dm_electric_car")
    // 删除已经存在的表
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_monthly_sales_trend")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_quarterly_sales_trend")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_yearly_sales_trend")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_region_sales_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_customer_age_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_customer_gender_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_customer_occupation_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_price_range_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_profit_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_battery_capacity_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_range_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_drive_type_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_charging_efficiency_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_intelligence_level_analysis")
    ss.sql("DROP TABLE IF EXISTS dm_electric_car.dm_transfer_status_analysis")

    /*****
     * 指标表1: 月度销售趋势表 (dm_monthly_sales_trend) - 新增品牌维度
     *****/
    ss.sql(
      """
      """
    )
  }
}
```

图5.9 SParkSql：DM层环境配置

```
ss.sql(
  """
  |CREATE TABLE IF NOT EXISTS dm_electric_car.dm_monthly_sales_trend (
  |  stat_month STRING COMMENT '统计月份(YYYY-MM)',
  |  brand STRING COMMENT '电动汽车品牌',
  |  total_sales_volume BIGINT COMMENT '月度总销量',
  |  total_production_volume BIGINT COMMENT '月度总产量',
  |  avg_sale_price DECIMAL(10,2) COMMENT '平均售价',
  |  total_profit DECIMAL(15,2) COMMENT '月度总利润'
  |)
  |COMMENT '月度销售趋势分析表'
  |ROW FORMAT DELIMITED
  |FIELDS TERMINATED BY '\t'
  |STORED AS TEXTFILE;
  """
)
```

```

|""|.stripMargin)

ss.sql(
  """
  |INSERT OVERWRITE TABLE dm_electric_car.dm_monthly_sales_trend
  |WITH monthly_base AS (
  |  SELECT
  |    stat_month,
  |    brand,
  |    SUM(total_sales_volume) AS total_sales_volume,
  |    SUM(total_production_volume) AS total_production_volume,
  |    ROUND(CASE WHEN IFNULL(SUM(customer_count),0) = 0 THEN 0 ELSE SUM(total_sale_price) / SUM(customer_count) END,2) AS customer_avg_price,
  |    SUM(total_profit) AS total_profit
  |    FROM dws_electric_car.dws_electric_car_month_agg
  |    GROUP BY stat_month, brand
  |)
  |SELECT
  |  stat_month,
  |  brand,
  |  total_sales_volume,
  |  total_production_volume,
  |  customer_avg_price,
  |  total_profit
  |FROM monthly_base
  |"""
)

```

图5.10 SParkSql: DM层建表和数据插入

5.4 特色数据分析

5.4.1 销售趋势分析与预测

销售趋势分析旨在揭示销售数据的时间规律并预测未来走势。本节首先利用statsmodels库中的seasonal_decompose函数对月度销售数据进行季节性分解，将原始序列拆解为趋势成分、季节成分和残差成分，以识别销售数据的内在周期性规律如图5.11所示。核心实现代码如下：

```


def time_series_decomposition_analysis(df, date_col, value_col, period=12):
    """对时间序列进行季节性分解分析"""
    # 按日期排序并设置索引
    df_sorted = df.sort_values(date_col).copy()
    df_sorted.set_index(date_col, inplace=True)
    df_sorted.index = pd.to_datetime(df_sorted.index)

    # 月度重采样（按月汇总）
    ts_data = df_sorted[value_col].resample('M').sum()

    # 季节性分解（加法模型）
    decomposition = seasonal_decompose(
        ts_data, model='additive', period=period
    )

    return decomposition

```






图5.11 时间序列分解图表

在时间序列分解的基础上，本研究进一步采用ARIMA模型对未来12个月的销售趋势进行预测如图5.12所示。Mishra DR等[10]验证了机器学习技术在电动汽车销量预测中的有效性，本研究在此基础上结合随机森林和梯度提升算法构建多维度预测模型。ARIMA模型（自回归积分滑动平均模型）能够有效捕捉时间序列的自相关性和趋势性，适用于汽车销售这类具有明显周期特征的数据预测。模型实现代码如下：

```
def arima_forecast(df, date_col, value_col, periods=12, order=(1, 1, 1)):
    """使用ARIMA进行时间序列预测"""
    # 数据预处理
    df_sorted = df.sort_values(date_col).copy()
    df_sorted.set_index(date_col, inplace=True)
    df_sorted.index = pd.to_datetime(df_sorted.index)
    # 月度重采样
    ts_data = df_sorted[value_col].resample('M').sum()
    ts_data = ts_data.fillna(ts_data.mean())
    # 训练ARIMA模型
    model = ARIMA(ts_data, order=order)
    results = model.fit()
    # 未来12个月预测
    forecast = results.get_forecast(steps=periods)
    return forecast
```






图5.12 销售预测图表

此外，为了能够达到更高的预测精度，还建立了多维度的销售预测模型，同时考虑了品牌、价格、产量等因素。借助随机森林和梯度提升两种集成学习算法进行预测，通过网格搜索进行超参数优化，对比更优模型如图5.13所示，最后选择均方误差最小的模型，主要代码为：

```
df_ml = df.copy()
# 复制特征列列表，避免影响外部变量
feature_cols = feature_cols.copy()
# 若特征为类别型，则进行标签编码
if col in df_ml.columns and df_ml[col].dtype == 'object':
# 基于时间序列交叉验证进行网格搜索
grid_search = GridSearchCV(
    model, param_grids[model_name], cv=TimeSeriesSplit(n_splits=5),
    scoring='neg_mean_squared_error', n_jobs=1
)
# 计算测试集均方误差（MSE）作为模型优劣指标
mse = mean_squared_error(y_test, y_pred)
```

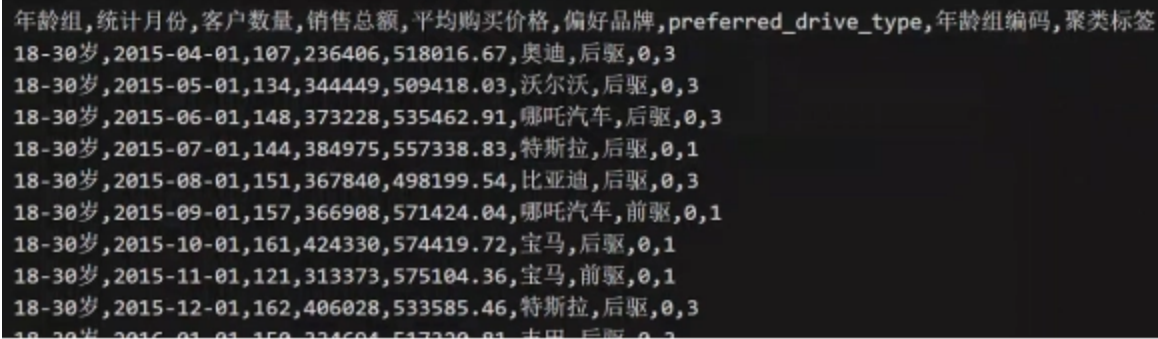
模型名称	均方误差(MSE)	平均绝对误差(MAE)	决定系数(R^2)
随机森林	737751334.2135847	17488.6672362851	0.7130048774405099
梯度提升	898688599.9288473	18204.569716583977	0.6503981315678292

图5.13 销售预测模型性能对比

5.4.2 客户细分与价值分析

客户细分和价值分析可以发现不同客户群体的特征差异，以便于准确地进行营销如图5.14所示。胡光川[11]采用DBSCAN算法对汽车销售数据进行聚类，K-Means算法应用于已知聚类数目的情况，两种方法针对不同的数据特征有各自的优势。本节采用K-Means聚类算法，选取客户数量、销售额、平均购买价格等作为聚类变量，采用StandardScaler对特征进行标准化，去除量纲差异，采用轮廓系数检测不同聚类数下的聚类质量，得到最优聚类数目，核心实现代码如下：

```
def customer_segmentation_analysis(df, feature_cols, n_clusters=5):
    """使用K-Means聚类进行客户细分"""
    X = df[feature_cols].copy()
    X = X.fillna(X.mean())
    scaler = StandardScaler()
    X_scaled = scaler.fit_transform(X)
    kmeans = KMeans(n_clusters=n_clusters, random_state=42, n_init=10)
    cluster_labels = kmeans.fit_predict(X_scaled)
    df['cluster'] = cluster_labels
    silhouette_avg = silhouette_score(X_scaled, cluster_labels)
    print(f" K-Means聚类完成 (n_clusters={n_clusters})")
    print(f" 轮廓系数: {silhouette_avg:.3f}")
```

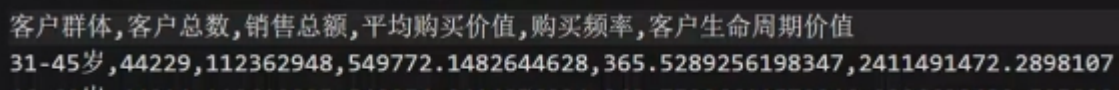


```
年龄组,统计月份,客户数量,销售总额,平均购买价格,偏好品牌,preferred_drive_type,年龄组编码,聚类标签
18-30岁,2015-04-01,107,236406,518016.67,奥迪,后驱,0,3
18-30岁,2015-05-01,134,344449,509418.03,沃尔沃,后驱,0,3
18-30岁,2015-06-01,148,373228,535462.91,哪吒汽车,后驱,0,3
18-30岁,2015-07-01,144,384975,557338.83,特斯拉,后驱,0,1
18-30岁,2015-08-01,151,367840,498199.54,比亚迪,后驱,0,3
18-30岁,2015-09-01,157,366908,571424.04,哪吒汽车,前驱,0,1
18-30岁,2015-10-01,161,424330,574419.72,宝马,后驱,0,1
18-30岁,2015-11-01,121,313373,575104.36,宝马,前驱,0,1
18-30岁,2015-12-01,162,406028,533585.46,特斯拉,后驱,0,3
18-30岁,2016-01-01,150,334604,517330.01,本田,后驱,0,3
```

图5.14 客户年龄聚类结果

在客户细分基础上，计算客户生命周期价值(Customer Lifetime Value)，可以计算各类客户的长期价值，采用简化模型，即采用平均购买价值、月均客户数和客户生命周期月数作为输入参数如图5.15所示，实现代码如下：

```
def calculate_customer_lifetime_value(df, customer_id_col='age_group', time_col='stat_month'):
    """计算客户生命周期价值 (CLV) """
    df = df.copy(); df[time_col] = pd.to_datetime(df[time_col]); clv_metrics = []
    # 按客户分群逐组计算CLV核心指标
    for group in df[customer_id_col].unique():
        group_data = df[df[customer_id_col] == group]
        # CLV模型: CLV = 平均购买价值 × 月均客户数 × 生命周期 (月)
        clv = avg_purchase * avg_monthly_customers * 12
        clv_metrics.append({'customer_segment': group, 'clv': clv})
    # 汇总并按CLV降序输出
    return pd.DataFrame(clv_metrics).sort_values('clv', ascending=False)
```



```
客户群体,客户总数,销售总额,平均购买价值,购买频率,客户生命周期价值
31-45岁,44229,112362948,549772.1482644628,365.5289256198347,2411491472.2898107
46-50岁,11011,110610005,540051.0111076031,363.75006611570016,2206630130.505000
```




图5.15 客户生命周期价值

5.4.3 产品特征分析

产品特征主要用于识别影响销量的主要产品因素和决策。本节利用随机森林和梯度提升两种方法计算各特征对销量的影响，识别出续航里程、电池容量、价格区间等影响因子，并分析重要性排名如图5.16所示，特征重要性代码如下：

```
def analyze_feature_importance(model, feature_cols):  
    """特征重要性分析"""  
    if not hasattr(model, 'feature_importances_'):  
        return None  
    importances = model.feature_importances_  
    importance_df = pd.DataFrame({'feature': feature_cols, 'importance': importances}).sort_values  
        ('importance', ascending=False)  
    return importance_df
```




图5.16 产品特征重要性排名

在价格优化方面，本研究采用对数-对数线性回归模型计算价格弹性系数。通过对价格和销量取自然对数后进行线性回归，回归系数即为价格弹性系数。当弹性系数小于-1时，表明产品富有弹性，降价可有效提升销量；当弹性系数介于-1和0之间时，表明产品缺乏弹性，提价对销量影响较小。价格弹性分析代码如下：

```
def price_optimization(df):  
    # 自动识别价格列和销量列  
    price_col = next((c for c in df.columns if any(k in c.lower() for k in ['price', '价格', '均价', '售价'])), None)
```

```

sales_col = next((c for c in df.columns if any(k in c.lower() for k in ['sales', '销量', '销售'])), None)

if not price_col or not sales_col: return {}

# 对数-对数线性回归：斜率即价格弹性系数
log_price, log_sales = np.log(data[price_col]), np.log(data[sales_col])

slope, intercept, r_value, p_value, std_err = stats.linregress(log_price, log_sales)

# 返回核心指标：弹性系数、拟合优度和显著性
return {'price_elasticity': slope, 'r_squared': r_value**2, 'p_value': p_value}

```

5.4.4 利润预测与过户分析

利润预测与过户分析侧重于预判未来利润走势和评估二手车市场活跃度。该部分包含利润预测建模、过户状态分析和过户价格预测三个环节：利润预测模型综合考虑时间特征（年份、月份、季度）、收入、成本等多维度变量，采用随机森林和梯度提升算法进行利润分析如图5.17所示，并通过时间序列分割进行交叉验证以确保模型的时序预测能力。利润预测模型核心代码如下：

```

def build_profit_prediction_model(df, insights=None):
# 构造时间/周期特征与品牌编码
    df = df.copy(); df['stat_month'] = pd.to_datetime(df['stat_month']); df['year'], df['month'],
df['quarter'] = df['stat_month'].dt.year, df['stat_month'].dt.month, df['stat_month'].dt.quarter
df['month_sin'], df['month_cos'] = np.sin(2*np.pi*df['month']/12), np.cos(2*np.pi*df['month']/12);
df['brand_encoded'] = LabelEncoder().fit_transform(df['brand'].astype(str))

# 基于测试集MSE选择最优模型
best_name = min(results, key=lambda n: mean_squared_error(y_test, results[n].best_estimator_.
predict(X_test)))

return results[best_name].best_estimator_, results, scaler

```

【利润分析】

- 有效分析记录：1,210 条
- 总利润：¥15,639,269.00
- 总收入：¥58,232,246,463.00
- 平均利润率：0.01%
- 利润率标准差：1.50%

利润排名前三的品牌：

1. 哪吒汽车
 - 总利润：¥9,969,202.00
 - 平均利润率：0.17%
 - 平均成本率：99.83%
2. 奥迪
 - 总利润：¥7,652,598.00
 - 平均利润率：0.08%
 - 平均成本率：99.92%
3. 蔚来



图5.17 利润分析

过户分析是从二手电动汽车市场上发现流通规律的一种分析方法。葛卓然[12]从消费者转售焦虑出发，认为二手车的保值率和过户次数对消费者决策有重要影响。通过对过户数量、过户价格、过户原因等各个维度的综合统计分析发现不同品牌在二手市场上的保值率、流通活跃度存在差异以及结合月度过户趋势发现交易的周期性变化趋势。可以发现过户次数越多的车辆平均过户价格越低，与转售焦虑理论是一致的如图5.18所示。核心代码如下：

```
def transfer_status_analysis(df):  
# 构造过户总金额（过户次数 × 平均过户价格）  
    d['transfer_amount'] = d['transfer_count'] * d['avg_transfer_price']  
# 品牌维度统计：过户总量/均值、平均过户价格、过户总金额  
brand_transfer = d.groupby('brand').agg({  
    'transfer_count': ['sum', 'mean'],  
    'avg_transfer_price': 'mean',  
    'transfer_amount': 'sum'  
}).round(2)  
# 过户状态分布统计（如正常过户、其他状态）  
transfer_status_dist = d['transfer_status'].value_counts()
```

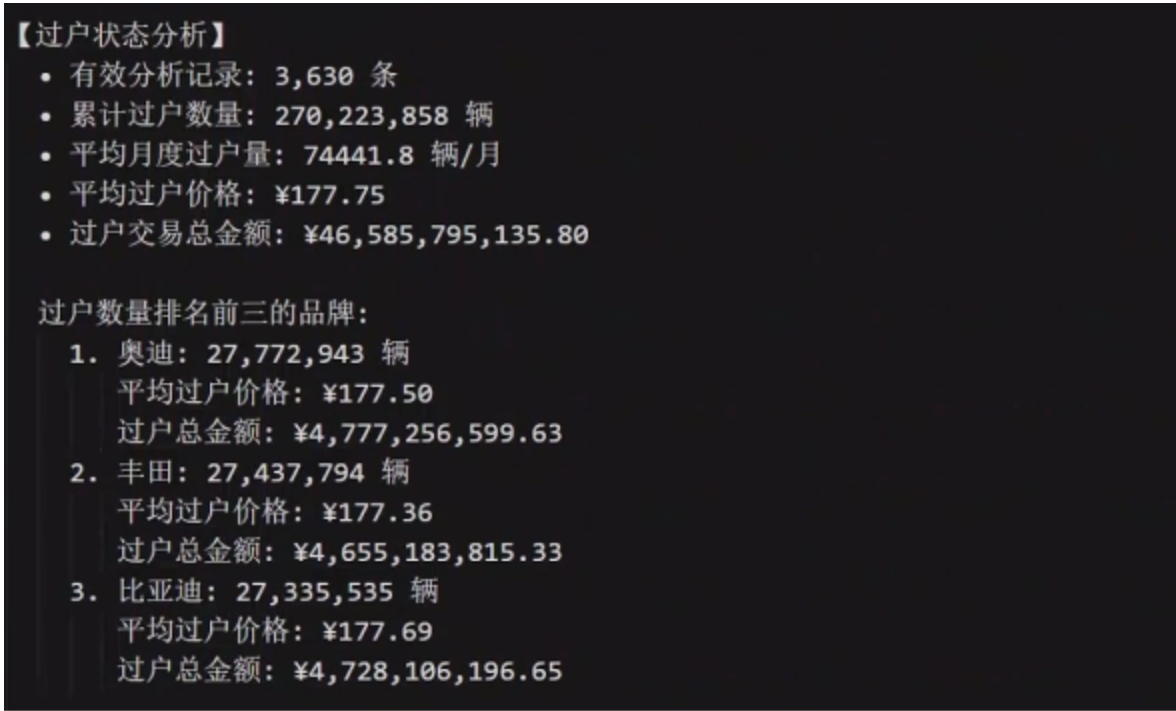


图5.18 过户状态分析

在过户状态分析的基础上，进一步构建过户价格预测模型，以预测二手电动汽车的平均过户价格。模型以过户数量、品牌编码、年份、月份、季度等作为特征变量，以平均过户价格作为目标变量。采用随机森林（Random Forest）和梯度提升（Gradient Boosting）两种集成学习算法分别建模，并通过GridSearchCV网格搜索进行超参数调优，以均方误差（MSE）为评价标准选取最优模型。核心代码如下：

```
def build_transfer_price_model(df, insights=None):
# 构建训练数据并标准化
    X, y = d[['transfer_count', 'brand_encoded', 'year', 'month', 'quarter']].fillna(0), d
    ['avg_transfer_price']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42);
scaler = StandardScaler()
    X_train, X_test = scaler.fit_transform(X_train), scaler.transform(X_test)
# 返回最优模型与评估指标
pred = gs.best_estimator_.predict(X_test)
    return gs.best_estimator_, {'model_name': best_name, 'rmse': np.sqrt(mean_squared_error
(y_test, pred)), 'mae': np.mean(np.abs(y_test - pred)), 'r2': r2_score(y_test, pred)}, scaler
```

5.4.5 综合关联分析与主成分分析

在前述各分析方向分别完成后，本节从全局视角进行跨模块关联分析，挖掘销售、客户、产品、利润等维度之间的内在联系。具体而言，将各地区销售数据与利润数据、过户数据进行关联构建综合数据视图，并计算各指标之间的皮尔逊相关系数以识别强相关关系如图5.19所示。跨模块关联分析代码如下：

```
def cross_module_correlation_analysis():
# 构建综合表（销售-利润-过户）并填补缺失
region_analysis = pd.DataFrame({
'销售总量': region_sales.loc[common_index],
'总利润': brand_profit.loc[common_index, '总利润'],
'平均利润率': brand_profit.loc[common_index, '平均利润率'],
'总过户数量': transfer_reindexed['总过户数量'] if '总过户数量' in transfer_reindexed.columns else 0
}).fillna(0)
# 计算皮尔逊相关系数并返回
return {'region': {'data': region_analysis, 'correlation_matrix': region_analysis.corr
(method='pearson')}}}
```

地区	销售总量	总利润	平均利润率	总过户数量
上海	33155496	9969202	0.17	27772943
北京	33701510	7652598	0.08	27437794
安徽	33794110	4426134	0.04	27335535

山东	33921934	3999595	0.04	27198779
江苏	33858620	2868185	0.05	26965256
江西	33711796	1633769	0.08	26950408
浙江	34049713	1107614	-0.03	26705912
深圳	34030679	-545649	-0.01	26649632

图5.19 跨模块关联分析

为了进一步降低数据维度，提取主要特征，本文采用PCA方法将多维数据进一步降维如图5.20所示，对各主成分进行解释方差比计算，得到能够解释80%以上方差的主成分数目，这样才能够保证信息完整性以及减少后续分析。


PCA分析代码如下：

```
def principal_component_analysis():
    # 执行PCA
    pca = PCA()

    pca_result = pca.fit_transform(StandardScaler().fit_transform(region_numeric))

    # 计算解释方差并确定累计方差>=80%的主成分数
    explained_variance = pca.explained_variance_ratio_
    cumulative_variance = np.cumsum(explained_variance)
    n_components = np.argmax(cumulative_variance >= 0.8) + 1 if np.any(cumulative_variance >= 0.8)
    else len(cumulative_variance)

    # 返回核心结果
    return {'region': {'pca': pca, '解释方差比': explained_variance, '累积解释方差':
cumulative_variance, '主成分数量': n_components, 'pca_result': pca_result}}
```






图5.20 PCA分析

5.5 本章小结


本章介绍了数据存储处理和特色分析过程，首先对环境搭建和设置以及数据仓库架构设计、DWD层数据清洗与格式校验、DWS层多维度数据聚合、DM层衍生指标表生成完成分层处理，其次对销售趋势分析与预测、客户细分与价值分析、产品特征分析、利润预测与过户分析、综合关联分析与主成分分析等特色数据分析过程进行了整合；通过Spark SQL程序进行加工，实现原始数据到指标的系统加工；通过Python机器学习算法进行销售数据的深度挖掘和预测分析，为进一步展示和进行数据可视化和业务决策提供数据基础。

6 可视化设计与实现

6.1 可视化工具选型与数据接入

本研究选用FineBI作为数据可视化工具，主要基于以下考虑：

- (1) FineBI能够直接连接MySQL数据库，无缝读取DM层导出的指标数据，无需额外的数据转换步骤；
 - (2) FineBI提供拖拽式的可视化组件配置方式，支持明细表、分组柱状图、环形图、玫瑰图、桑基图、地图等多种图表类型，能够满足多样化的展示需求；
 - (3) FineBI内置多维度筛选、排序和联动功能，能够实现交互式数据探索；
 - (4) FineBI支持仪表盘的组合布局，可将多个分析维度的图表整合到统一的展示界面中，便于决策者全面把握数据全貌。数据接入的具体操作步骤如下：首先，打开FineBI管理系统并登录，在管理系统中选择“数据连接管理”功能模块如图6.1所示；
- 吴剑飞等[4]在汽车销售数据分析研究中同样强调了可视化展示对数据分析成果落地的重要作用，进一步验证了本研究选用FineBI的合理性。






图6.1 连接数据库

然后，新建数据连接并选择MySQL类型，配置数据库名称、主机地址、端口号、用户名和密码等连接参数，通过测试连接验证配置正确性，如图6.2所示；




图6.2 配置数据库信息

连接成功后，进入“公共数据”界面，创建名为“电动汽车销售指标数据”的文件夹，将MySQL数据库中DM层的15张指标分析表批量导入该文件夹中，如图6.3所示；




图6.3 导入数据表

最后，在“我的分析”界面中创建“汽车销售指标分析”文件夹，并在该文件夹下新建分析主题，将已导入的15张指标表数据加载至分析主题中，完成数据接入。数据接入完成后，即可在分析主题中基于各指标表的字段创建可视化组件，如图6.4所示。




图6.4 创建分析主题

6.2 特色图表设计思路

根据各分析方向的数据特点和展示需求，15张DM层指标表分别选用最佳图表类型设计，具体思路如下：

（1）销售趋势类图表：月度销售趋势表如图6.5、季度销售趋势表如图6.6两个为明细表形式，以统计月份YYYY-MM或统计季度YYYY-Q为行维度，展示电动汽车品牌、平均售价、总产量、总销量、总利润等指标，可以按列排序、分页显示，便于查看不同时间段各品牌详细数据；年度销售趋势表如图6.7为玫瑰图（南丁格尔图）展示，以品牌为扇区维度、年度销量为扇区半径，并标明平均售价数值，便于查看各品牌年度销售规模的大小。地区销售分析表如图6.8为地图组件形式，以产地为地理维度，采用气泡标记在中国地图上标注各地区销售分布情况，展示不同地区销售分布情况。

月度销售趋势表						
统计月份(YYYY-MM)	电动汽车品牌	平均售价	月度总产量	月度总销量	月度总利润	
2015-04	宝马	509,879.57	351,760	169,002	545,522	
2015-04	小鹏汽车	550,221.87	324,552	156,122	-450,558	
2015-04	比亚迪	579,019.56	278,741	162,893	848,549	
2015-04	沃尔沃	526,266.05	285,346	126,818	-18,929	
2015-04	特斯拉	521,857.73	342,830	168,811	-896,725	
2015-04	蔚来	567,070.75	331,337	131,223	-14,458	
2015-04	雷克萨斯	558,789.95	402,170	185,963	-384,662	
2015-05	丰田	551,348.13	386,371	191,633	-751,477	
2015-05	哪吒汽车	528,610.97	498,353	258,620	106,463	
2015-05	奥迪	514,163.53	458,812	207,845	-508,324	
2015-05	宝马	566,827.49	358,420	191,021	-678,348	
2015-05	小鹏汽车	490,824.47	489,061	250,175	81,823	
2015-05	比亚迪	528,805.04	448,580	218,103	-429,106	
2015-05	沃尔沃	524,661.42	606,397	326,078	526,028	
2015-05	特斯拉	584,839.44	408,498	208,743	533,481	
2015-05	蔚来	564,952.78	458,074	226,304	-368,474	
2015-05	雷克萨斯	492,198.71	417,747	214,251	-506,186	
2015-06	丰田	605,553.05	423,744	189,850	642,127	
共 条数据					1	/13 >

图6.5 月度销售趋势表

季度销售趋势表						
统计季度(YYYY-Q)	电动汽车品牌	季度总产量	季度总销量	季度总利润	平均售价	
2015-Q2	丰田	1,266,455	-703,696	590,683	568,219.24	
2015-Q2	哪吒汽车	1,215,708	509,071	595,181	558,711.04	
2015-Q2	奥迪	1,346,992	1,228,954	642,309	526,702.78	
2015-Q2	宝马	1,105,695	-877,232	557,218	532,889.19	
2015-Q2	小鹏汽车	1,174,180	1,341,946	583,182	533,772.86	
2015-Q2	比亚迪	1,181,476	-182,750	591,439	542,089.31	
2015-Q2	沃尔沃	1,309,663	-241,979	706,705	526,915.53	
2015-Q2	特斯拉	1,228,756	-852,731	617,224	547,541.54	
2015-Q2	蔚来	1,191,265	-942,045	587,961	569,292.21	
2015-Q2	雷克萨斯	1,341,157	-342,611	669,024	537,271.48	
2015-Q3	丰田	1,392,333	-425,792	696,739	558,171.96	
2015-Q3	哪吒汽车	1,249,327	958,747	678,504	551,328.88	
2015-Q3	奥迪	1,173,309	2,089,277	617,213	556,665.08	
2015-Q3	宝马	1,216,979	-1,435,357	606,006	531,524.85	
2015-Q3	小鹏汽车	1,234,566	917,322	586,555	576,846.22	
2015-Q3	比亚迪	1,374,060	3,246,060	677,122	548,623.23	
2015-Q3	沃尔沃	1,284,575	1,208,008	670,757	547,148.24	
共 10 条数据					1	/6 >

图6.6 季度销售趋势表




图6.7 年度销售趋势表




图6.8 地区销售趋势表

(2) 客户分析类图表：客户年龄分析表如图6.9所示采用分组柱状图展示，以品牌为横轴，按18-30岁、31-45岁、46-60岁等年龄段分组，纵轴分层展示客户数量、销量、平均购买价格等多个指标，通过渐变色区分年龄段，便于直观对比不同年龄群体在各品牌间的购车差异。客户性别分析表如图6.10所示采用环形图展示，以品牌和性别（男/女）为分类维度，通过环形扇区面积反映各品牌不同性别客户的数量分布，并在扇区旁标注具体客户数量。客户职业分析表如图6.11所示采用分组柱状图展示，横轴为品牌，纵轴分层展示各职业群体的客户数量、平均购买价格、购买能力评分等指标，通过多色柱状对比不同职业的购车特征。




图6.9 客户年龄分析表




图6.10 客户性别分析表




图6.11 客户职业分析表

(3) 产品特征类图表：价格区间表：玫瑰图（南丁格尔图），按品牌与价格区间（0-20万、20-40万、40-60万、60万以上），分别用扇区半径表示不同价格区间的销量，标注销量、客户满意度评分等指标。电池容量表：如图6.13所示，用分组柱状图，按电池容量区间（50-80kWh、80-110kWh等），分别表示不同品牌平均售价、平均续航里程、销量。续航里程表：如图6.14所示，用环形图，以品牌为分类，用环形扇区展示各品牌续航里程，标签标注充电频率、平均电池容量等指标。驱动形式表：如图6.15所示，用分组柱状图，以品牌为分组，纵横分层表示平均售价、销量和驱动形式占比，多行图表对比不同驱动形式（前驱、后驱、四驱）的表现；充电效率表：如图6.16所示采用明细表展示，包括统计月份、电动汽车品牌、充电效率区间（快充/慢充/混合充）、平均售价、销量等字段，支持按充电效率区间筛选和排序，便于精细分析不同充电类型的销售。智能化水平分析表如图6.17所示采用桑基图展示，左侧为电动汽车品牌节点，右侧为智能化等级（L2至L5）节点，通过流线宽度表示各品牌在不同智能化等级上的销量分布，直观揭示品牌与智能化水平之间的对应关系。




图6.12 价格区间分析表




图6.13 电池容量分析表




图6.14 续航里程分析表



图6.15 驱动形式分析表

充电效率分析表

统计月份	电动汽车品牌	充电效率区间	平均售价	销量
2015-04	丰田	快充	230.53	86,752
2015-05	丰田	快充	220.99	100,532
2015-06	丰田	快充	312.93	78,759
2015-07	丰田	快充	262.05	110,159
2015-08	丰田	快充	237.89	106,699
2015-09	丰田	快充	221.29	126,390
2015-10	丰田	快充	152.9	128,154
2015-11	丰田	快充	179.35	124,641
2015-12	丰田	快充	243.02	98,663
2016-01	丰田	快充	197.89	115,148
2016-02	丰田	快充	184.7	104,288
2016-03	丰田	快充	299.94	58,842
2016-04	丰田	快充	240.61	79,986
2016-05	丰田	快充	212.44	97,958
2016-06	丰田	快充	182.95	98,837
2016-07	丰田	快充	235.98	102,376

共 2,420 条数据

图6.16 充电效率分析表




图6.17 智能化水平分析表

(4) 利润过户类图表：利润分析表如图6.18所示，由明细表形式展示，表示统计月份、电动汽车品牌、单车利润（总利润/总销量）、利润率（利润/收入×100）、总成本（总收入-总利润）、总利润等，可分页浏览和排序，方便分析各品牌各时期的盈利情况。过户状态分析表如图6.19所示，由交叉表形式展示，以电动汽车品牌为行分别展示过户原因分析、过户状态、平均过户价格、过户数量等字段，各品牌行可展开查看不同过户状态的详细数据，即可展现不同品牌间的过户差异；各图表均基于DM层指标表中的已有字段，内容与数据分析结果一一对应。

利润分析表												
+	统计月份	三	电动汽车品牌	三	单车利润(总利润/总销量)	三	利润率(利润/收入*100%)	三	总成本(总收入-总利润)	三	总利润	三
+	2015-04				6.03		2.93		372,562,070		1,151,757	
+	2015-05				-10.97		-4.84		462,514,264		-1,994,120	
+	2015-06				1.15		-0.52		469,081,007		-220,710	
+	2015-07				15.92		7.12		470,237,668		3,453,167	
+	2015-08				6.65		2.64		469,320,036		1,325,061	
+	2015-09				14.21		6.88		483,055,089		3,142,223	
+	2015-10				17.92		8.74		497,306,153		4,061,803	
+	2015-11				6.17		2.1		499,719,461		1,226,160	
+	2015-12				-9.93		-4.94		477,287,535		-2,402,437	
+	2016-01				9.27		4.27		434,592,919		1,462,868	
+	2016-02				14.65		6.54		472,169,679		3,343,312	
+	2016-03				0.41		-0.76		473,464,042		318,900	
+	2016-04				-4.55		-2.33		489,227,713		-746,558	
+	2016-05				13.23		7.16		464,653,335		3,794,464	
+	2016-06				-3.57		-1.45		477,960,095		-641,115	
+	2016-07				-8.85		-3.68		492,497,973		-1,536,688	
+	2016-08				22.75		10.34		462,653,892		4,891,776	
+	2016-09				-9.46		-3.74		464,933,292		-2,103,798	

图6.18 利润分析表

过户状态分析表														
- 电动汽车品牌			- 过户原因分析			- 过户状态			- 平均过户价格			- 过户数量		
- 丰田			-	二次过户，车辆使用频率较高/性价比偏低，保值率有所下降		已过户两次		174.16			9,164,782			
			-	新车未过户，无转让需求，车辆保值率高		未过户		180.12			9,061,492			
			-	首次过户，多为个人换车/资金周转，车辆使用周期较短		已过户一次		177.8			9,191,520			
- 哪吒汽车			-	二次过户，车辆使用频率较高/性价比偏低，保值率有所下降		已过户两次		174.3			9,073,144			
			-	新车未过户，无转让需求，车辆保值率高		未过户		180.25			8,942,556			
			-	首次过户，多为个人换车/资金周转，车辆使用周期较短		已过户一次		183.89			8,622,117			
- 奥迪			-	二次过户，车辆使用频率较高/性价比偏低，保值率有所下降		已过户两次		177.64			8,905,240			
			-	新车未过户，无转让需求，车辆保值率高		未过户		176.35			9,445,993			
			-	首次过户，多为个人换车/资金周转，车辆使用周期较短		已过户一次		178.51			9,421,710			
- 宝马			-	二次过户，车辆使用频率较高/性价比偏低，保值率有所下降		已过户两次		181.51			8,921,341			
			-	新车未过户，无转让需求，车辆保值率高		未过户		178.35			9,123,966			
			-	首次过户，多为个人换车/资金周转，车辆使用周期较短		已过户一次		183.17			8,604,325			
- 小鹏汽车			-	二次过户，车辆使用频率较高/性价比偏低，保值率有所下降		已过户两次		179.97			8,977,304			
			-	新车未过户，无转让需求，车辆保值率高		未过户		180.52			8,825,709			
			-	首次过户，多为个人换车/资金周转，车辆使用周期较短		已过户一次		175.05			9,147,395			
- 比亚迪			-	二次过户，车辆使用频率较高/性价比偏低，保值率有所下降		已过户两次		177.82			9,170,946			
			-	新车未过户，无转让需求，车辆保值率高		未过户		177.46			9,171,336			
			-	首次过户，多为个人换车/资金周转，车辆使用周期较短		已过户一次		173.29			8,999,363			

图6.19 过户状态分析表

6.3 交互式仪表盘功能实现

基于FineBI构建交互式仪表盘，实现以下交互功能：

- （1）多维度筛选与排序：明细表类组件（月度销售趋势表、季度销售趋势表、充电效率分析表、利润分析表）的列标题支持点击排序功能，用户可按统计月份、销量、利润率等字段升序或降序排列数据。交叉表类组件（过户状态分析表）支持行展开收起操作，可逐级查看各品牌在不同过户状态下的详细数据。分组柱状图类组件（客户年龄分析表、客户职业分析表、电池容量分析表、驱动形式分析表）支持通过图例筛选特定分组的数据展示。
- （2）组件创建与配置：在分析主题中，依次为月度销售趋势表、季度销售趋势表、年度销售趋势表、地区销售分析表、客户年龄分析表、客户性别分析表、客户职业分析表、价格区间分析表、利润分析表、电池容量分析表、

续航里程分析表、驱动形式分析表、充电效率分析表、智能化水平分析表、过户状态分析表创建对应的可视化组件。每个组件通过拖拽字段至维度区和指标区完成数据绑定，根据数据特点选择明细表、分组柱状图、环形图、玫瑰图、桑基图、地图或交叉表等图表类型，配置颜色方案、标签显示和数值格式等样式属性。

（3）仪表盘布局：将15个可视化组件按分析方向进行逻辑分组，销售趋势类图表置于仪表盘上方，客户分析类图表居中展示，产品特征类图表和利润过户类图表分列下方，决策者可在统一界面中快速浏览全局分析结果，实现从宏观趋势到微观细节的层次化数据探索。

6.4 本章小结

本章介绍了FineBI可视化设计与实现的整体过程，包括FineBI工具的选择和接入数据、15张DM层指标表的图表设计思路（包括明细表、分组柱状图、环形图、玫瑰图、桑基图、地图和交叉表等7种图表）、交互式仪表盘组件创建和多维度筛选排序功能的实现以及具体数据的可视化结果。FineBI将DM层指标数据转换为直观图表和交互式仪表盘，从而将复杂数据分析结果以通俗易懂的方式呈现给决策者，使得数据分析结果更有应用价值。

7 总结与展望

7.1 研究成果总结

本研究基于Hive+Spark大数据技术，构建了一套完整的汽车销售数据分析系统，实现了从数据采集、存储、处理、分析到可视化展示的全流程覆盖。主要研究成果如下：

（1）技术实现方面：成功构建了基于Hive+Spark的大数据处理平台，通过Spark SQL与Hive的深度集成，实现了数据仓库四层架构（ODS→DWD→DWS→DM）的分层处理，验证了大数据技术在汽车销售数据分析中的有效性和高效性。系统能够通过DataX实现MySQL与HDFS之间的双向数据传输，确保数据流转的完整性。

（2）特色分析方面：基于DM层15张指标分析表，从销售趋势、客户特征、产品特性、利润过户四个方向开展了深度分析。销售趋势分析发现销售数据具有明显的季节性特征，年底和春节前后为销售高峰期；客户分析识别出不同年龄段、性别、职业群体的差异化购车偏好，年轻客户更关注智能化配置和续航里程，中年客户更注重舒适性和安全性；产品特征分析表明价格是影响销量的首要因素，其次是续航里程和智能化水平；利润分析揭示了不同品牌利润率的显著差异，高端品牌利润率较高但销量相对较低。上述分析结论与高小杰[5]基于销售大数据的客户偏好分析方法、崔想[8]的盈利模式比较研究相互印证，进一步验证了本研究分析方法的有效性。

（3）方法流程方面：提出了适用于汽车销售行业的数据分析方法和流程，包括数据采集（Shell+DataX）、数据存储（MySQL+HDFS+Hive）、数据处理（Spark SQL分层处理）、数据分析（SQL查询+Python机器学习）和数据可视化（FineBI交互式仪表盘）的完整技术路线，具有通用性和可复制性。

（4）创新点方面：将Hive+Spark系统地应用于汽车销售数据分析领域，设计了多维度、多层次的分析体系，通过Spark SQL的高级语法（窗口函数、CTE、CASE WHEN等）实现了复杂的业务指标生成，并结合Python机器学习算法实现了聚类分析、特征重要性分析和时间序列预测等深度挖掘。

7.2 研究不足

本研究仍存在以下不足之处：

（1）数据来源方面：数据主要依赖公开数据集，与实际业务数据在规模、实时性和丰富度方面存在差距，实际企业数据的获取和处理仍需进一步研究。

(2) 实时分析方面：当前系统主要支持批量处理模式，实时数据分析能力有待提升，无法满足对市场动态变化的即时响应需求。

(3) 预测模型方面：预测模型的准确性仍有优化空间，可以尝试更多算法和特征工程方法，进一步提升预测精度。

(4) 可视化方面：当前可视化展示以基础图表为主，在高级分析图表和自动化报告生成方面还有提升空间。

7.3 未来优化方向

结合汽车销售行业的发展，未来进一步优化的方向是：

(1) 实时数据处理能力的提升，使用Apache Flink或Spark structured Streaming等流式计算方法进行数据分析和动态预警。

(2) 增加外界数据的获取，如社交媒体数据、经济指标、政策法规等数据，丰富分析维度和深度。

(3) 深度学习方法的应用，如LSTM模型提高时间序列分析精度。

(4) 提供一个智能决策系统，进行决策的自动化分析和个性化建议推送。

参考文献

- [1]张蓉. 电动汽车及车电销售“快增”态势对成品油销售的影响及对策[J]. 石油商技, 2025, 43(05):90-94.
- [2]郭梓云. 全球电动汽车市场持续扩大[N]. 人民日报, 2024-10-17(018).
- [3]本刊. 1-11月, 我国新能源汽车销售830.4万辆, 同比增长36.74%[J]. 商用汽车, 2023, (06):7.
- [4]吴剑飞, 孟祥宇. 运用大数据技术对汽车销售情况进行有效数据分析研究[J]. 吉林广播电视大学学报, 2025, (05):34-36+52.
- [5]高小杰. 基于销售大数据的电动汽车市场偏好信息挖掘及适应性设计智能决策[D]. 广东工业大学, 2023.
- [6]冯秀秀. MG公司新能源汽车营销策略研究[D]. 东北农业大学, 2022.
- [7]Huang S, Li Y, Xi Z. An Empirical Study on the Impact of Key Technology Configurations on Sales of Battery Electric Vehicles: Evidence from the Chinese Market[J]. World Electric Vehicle Journal, 2025, 16(9): 522-522.
- [8]崔想. 新能源汽车企业盈利模式比较研究[D]. 长江大学, 2023.
- [9]刘柯. 不同电动汽车市场结构下政府补贴策略及充电站投资决策研究[D]. 西南交通大学, 2023.
- [10]Mishra DR, Dash KS, Chudjuarjeen S, et al. Hybrid LSTM-GBRT based machine learning technique implementation for electric vehicle sales prediction analysis[J]. International Journal of Sustainable Engineering, 2024, 17(1): 843-858.
- [11]胡光川. 基于DBSCAN算法的汽车销售分析系统设计与实现[D]. 厦门理工学院, 2024.
- [12]葛卓然. 基于消费者转售焦虑视角的电动汽车销售策略研究[D]. 南京财经大学, 2025.
- [13]赵明奎, 万波, 孙彬, 等. 成品油销售企业电动汽车充电站低成本建设研究[J]. 车用能源储运销技术, 2024, 2(05):63-69.
- [14]杨文明. 智能电动汽车视域下汽车销售和售后服务行业不同未来状态下的业务能力分析(一)[J]. 汽车维护与修理, 2022, (17):1-9.

[15]张琪. 不同补贴政策下电动汽车制造商的共享模式选择策略研究[D]. 东北大学, 2022.

致 谢

这篇论文的完成意味着四年的本科生活即将结束，回顾这四年的学习经历，我深深感受到自己的每一点进步离不开师长和同学们的辛勤努力。

首先我要感谢我的指导老师郑心科老师，从开题构思、资料收集到探究方案拟定、实验设计再到论文的撰写修改，对于这个过程中的每个步骤，郑老师都倾注了大量的心血，他的治学态度、学术基础和前沿观点，对于研究方向的指引、对于研究方法的引导，在我遇到瓶颈或者难题的时候，郑老师总是耐心地和我一起研究问题的原因，他的鼓励是我可以坚持下来的动力所在。

我还要感谢大数据与人工智能学院所有的授课老师，大学四年里，他们系统地介绍了信息库、大统计结果技术栈到编程基础和系统结构等等基础知识，这些基础知识是整个毕业设计的基础；也要感谢帮助我学习和交流论文的同学，我在论文写作过程中和同学们就DataX数据同步、Spark作业性能调优等一些实际问题展开了深入讨论，并最终攻克了许多难关，学到了许多很多高于课本的经验。

最后，再次感谢大数据与人工智能学院所有领导和老师。感谢大数据与人工智能学院给我们良好的学习氛围、提供良好的实验环境，让我们在实践中加深理论研究，完成我们的学习。

须知：

- 报告编号系送检论文检测报告在本系统中的唯一编号。
- 本报告结合AI大模型自动生成，结果仅供参考。
- 报告支持中、英文内容检测。



微信公众号

唯一官网：<https://vpcs.fanyu.com> | 客服邮箱：vpcs@fanyu.com | 客服热线：400-607-5550 | 客服QQ：4006075550